

(1) 表 3-3 显示了两个未知类别情况下的未知类平均分类结果。结果表明, 所提出的 VLHUC 模型能够有效应用于高光谱图像未知类分类任务中。尽管测试阶段存在未知类别, 该方法不仅对已知类别实现了较高分类精度, 对未知类别也取得了可观效果。具体分析如下: 所有对比方法对 y 已知类别的分类精度均较高。总体而言, 基于全局学习的分类方法在该场景下优于基于局部学习的方法。例如, 在 Pavia 数据集上, MSSGU 方法的已知类别总体精度 $S(oa)$ 和平均精度 $S(aa)$ 分别比 SSFTT 高 0.58 和 0.73 个百分点。传统高光谱分类方法无法在零样本学习任务中识别未知类别。在三个数据集中, 所有对比方法的未知类别总体精度 $U(oa)$ 和平均精度 $U(aa)$ 均为零, 因此其调和平均精度也为零。VLHUC 模型在保持高已知类别精度的同时, 展现出强大的未知类别识别能力。例如, 在 QUH-Qingyun 数据集上, VLHUC 的未知类别平均总体精度达 69.63%, 平均精度达 74.26%, 证明了其对新类别的泛化能力。然而, 引入未知类分类机制对已知类别性能略有影响, 其 $S(oa)=94.52\%$, $S(aa)=92.31\%$ 较其他方法略有下降。其他两个数据集也得出类似结论, 但 VLHUC 仍对已知类别保持良好分类能力。

表 3-3 不同方法在高光谱数据集上的分类结果
Table 3-3 Classification results of different methods on HSI datasets

		CNN	DBDA	SSFTT	CT-Mixer	CNN-GCN	MSSGU	UNet	VLHUC
Pavia University	$S(oa)$ (%)	99.07	99.21	99.33	99.904	99.90	99.91	99.75	96.79
	$U(oa)$ (%)	0	0	0	0	0	0	0	60.79
	$H(oa)$ (%)	0	0	0	0	0	0	0	71.17
	$S(aa)$ (%)	98.96	98.94	99.12	98.89	99.85	99.85	99.49	94.52
	$U(aa)$ (%)	0	0	0	0	0	0	0	57.16
	$H(aa)$ (%)	0	0	0	0	0	0	0	68.38
Houston	$S(oa)$ (%)	97.37	96.74	97.11	97.86	98.54	98.41	97.64	90.96
	$U(oa)$ (%)	0	0	0	0	0	0	0	70.50
	$H(oa)$ (%)	0	0	0	0	0	0	0	78.28
	$S(aa)$ (%)	97.46	96.91	97.22	98.03	98.80	98.63	97.89	93.20
	$U(aa)$ (%)	0	0	0	0	0	0	0	72.66
	$H(aa)$ (%)	0	0	0	0	0	0	0	80.79
QUH-Qingyun	$S(oa)$ (%)	96.20	96.87	95.42	96.48	97.95	97.85	98.94	96.17
	$U(oa)$ (%)	0	0	0	0	0	0	0	69.63
	$H(oa)$ (%)	0	0	0	0	0	0	0	78.92
	$S(aa)$ (%)	90.77	92.52	89.56	91.47	95.40	96.24	94.89	93.55
	$U(aa)$ (%)	0	0	0	0	0	0	0	74.26
	$H(aa)$ (%)	0	0	0	0	0	0	0	82.17

(2) 图 3-9、图 3-10 和图 3-11 展示了所提 GZSL 模型在三个数据集上, 针

对不同未知类别组合的分类性能。结果表明，该方法在保持可见类别高分类精度的同时，也具备了合理的零样本分类能力。然而，分类性能会随未知类别的具体组合而变化，在部分类别组合下模型表现相对较差。




图 3-9 Pavia University 数据集的已知类、未知类和调和精度

Fig.3-9 The mean seen, unseen, and harmonic accuracies on the Pavia University dataset




图 3-10 合并 Houston013 数据集的已知类、未知类和调和精度

Fig.3-10 The mean seen, unseen, and harmonic accuracies on the merged Houston2013 dataset

以 Pavia University 数据集为例，当第三类“砂砾”被设为未知类别时，模型难以对其进行正确识别；第八类“砖块”也存在类似问题。这可能是因为这两类均为道路建设中常见的地表材料，不仅语义关联性强，且缺乏独特空间特征。Pavia University 数据集的 RGB 图像显示，这些地物类型在光谱和空间特征上高度相似，加剧了分类难度。合并后的 Houston2013 数据集上也观察到类似规律。相比之下，模型在 QUH-Qingyun 数据集上表现更为稳定。在大多数类别

组合下，模型对于可见类别与未知类别均能保持较高的分类精度。但当第三类与第六类被设为未知类别时，未知类别的总体精度（OA）下降至约 30%，而平均精度（AA）维持在 60% 左右。这可能是由于“汽车”与“沥青路”两类地物高度相关且常伴随出现，导致二者的区分难度较大。




图 3-11 QUH-Qingyun 数据集的已知类、未知类和调和精度

Fig.3-11 The mean seen, unseen, and harmonic accuracies on the QUH-Qingyun dataset

上述结果表明，模型性能受到高光谱图像分辨率、类别粒度以及与 CLIP 训练数据的匹配度共同影响。空间分辨率越高，伪标签精度越高，进而提升零样本分类性能；反之，当类别定义偏离常规、类间纠缠度增加时，伪标签精度会下降，最终对整体性能产生负面影响。

(3) 表 3-4、表 3-5 与表 3-6 展示了三个数据集上选定未知类别组合的分类结果，涵盖了识别效果性能较好与识别较为困难的集中类别组合。其中可见类别精度（S）、未知类别精度（U）与调和精度（H）均以平均值形式报告。

从表 3-4、表 3-5 与表 3-6 的结果可见，传统方法因缺乏广义零样本分类机制与外部辅助知识，无法识别未知类别，导致这些类别的精度为零。相比之下，所提方法在不同未知类别组合下表现出差异化性能，其中存在若干值得关注的典型情况。在 Pavia University 数据集上，当“柏油路（第 1 类）”与“草地（第 2 类）”作为未知类别时，模型取得了较高的未知类分类精度。这两类地物与其他类别的空间纠缠程度较低，且属于常见地物，使得 CLIP 能够生成高质量伪标签，从而提升分类精度。然而，对于“金属屋棚（第 5 类）”与“地砖（第 8 类）”的组合，模型对金属屋棚识别效果良好，但对砖块的识别性能较差。这种差异可能源于金属屋棚与 CLIP 的先验知识更契合，而砖块在遥感图像中缺乏独特的视觉特征，导致识别困难。类似地，模型在“砂砾（第 3 类）”与“沥青

表 3-4 Pavia University 数据集测试数据分类结果 (均值 $\pm$ 标准差)Table 3-4 Testing data classification results (mean values $\pm$ standard deviation) on the Pavia University

Dataset									
	(1,2)*			(5,8)			(3,7)		
	CT-Mixer	MSSGU	VLHUC	CT-Mixer	MSSGU	VLHUC	CT-Mixer	MSSGU	VLHUC
	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	96.29 $\pm$ 0.80	99.97 $\pm$ 0.03	100.0 $\pm$ 0.00	99.11 $\pm$ 0.50	99.97 $\pm$ 0.05	100.0 $\pm$ 0.00	99.11 $\pm$ 0.57
	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	60.65 $\pm$ 0.49	99.99 $\pm$ 0.02	100.0 $\pm$ 0.00	99.77 $\pm$ 0.17	98.58 $\pm$ 2.81	100.0 $\pm$ 0.00	99.25 $\pm$ 0.18
	93.61 $\pm$ 10.98	100.0 $\pm$ 0.00	93.90 $\pm$ 0.77	99.55 $\pm$ 0.17	100.0 $\pm$ 0.00	93.48 $\pm$ 1.12	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	15.70 $\pm$ 1.25
	98.74 $\pm$ 0.28	99.21 $\pm$ 0.36	81.94 $\pm$ 1.42	98.49 $\pm$ 0.14	99.13 $\pm$ 0.47	83.90 $\pm$ 2.46	98.87 $\pm$ 0.41	98.36 $\pm$ 0.89	83.90 $\pm$ 2.32
	99.80 $\pm$ 0.16	100.0 $\pm$ 0.00	99.67 $\pm$ 0.40	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	85.59 $\pm$ 0.31	99.75 $\pm$ 0.15	100.0 $\pm$ 0.00	99.44 $\pm$ 0.57
	99.82 $\pm$ 0.25	100.0 $\pm$ 0.00	99.61 $\pm$ 0.54	99.64 $\pm$ 0.63	100.0 $\pm$ 0.00	99.48 $\pm$ 0.56	92.69 $\pm$ 14.22	100.0 $\pm$ 0.00	98.92 $\pm$ 1.01
	99.89 $\pm$ 0.22	100.0 $\pm$ 0.00	98.46 $\pm$ 0.82	99.72 $\pm$ 0.53	100.0 $\pm$ 0.00	98.27 $\pm$ 0.99	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	36.33 $\pm$ 0.15
	99.34 $\pm$ 0.46	100.0 $\pm$ 0.00	91.88 $\pm$ 1.24	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	17.27 $\pm$ 2.82	99.70 $\pm$ 0.32	99.99 $\pm$ 0.01	91.31 $\pm$ 1.05
	98.69 $\pm$ 0.95	99.93 $\pm$ 0.05	84.49 $\pm$ 2.10	99.82 $\pm$ 1.38	99.98 $\pm$ 0.04	85.45 $\pm$ 3.31	99.00 $\pm$ 0.69	99.96 $\pm$ 0.05	86.00 $\pm$ 4.13
OA (%)	39.15 $\pm$ 0.58	39.60 $\pm$ 0.03	79.24$\pm$0.28	87.49 $\pm$ 0.06	87.64 $\pm$ 0.03	89.94$\pm$0.45	89.98 $\pm$ 1.82	91.48$\pm$0.06	90.78 $\pm$ 0.07
AA (%)	76.65 $\pm$ 1.28	77.68 $\pm$ 0.04	89.66$\pm$0.29	77.35 $\pm$ 0.11	77.68 $\pm$ 0.05	84.70$\pm$0.93	76.51 $\pm$ 1.60	77.59$\pm$0.09	78.89 $\pm$ 0.53
K $\times$ 100	33.99 $\pm$ 0.60	34.56 $\pm$ 0.17	73.93$\pm$0.35	83.49 $\pm$ 0.12	83.55 $\pm$ 0.09	86.64$\pm$0.62	86.62 $\pm$ 2.49	88.62$\pm$0.08	87.76 $\pm$ 0.11
S(aa) (%)	98.55 $\pm$ 1.64	99.88$\pm$0.05	92.85 $\pm$ 0.60	99.45 $\pm$ 0.14	99.87$\pm$0.07	94.21 $\pm$ 0.88	98.37 $\pm$ 2.05	99.76$\pm$0.12	93.99 $\pm$ 0.80
U(aa) (%)	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	78.47$\pm$0.41	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	51.43$\pm$1.42	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	26.02$\pm$0.57
H(aa) (%)	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	85.06$\pm$0.30	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	66.53$\pm$1.35	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	40.75$\pm$0.65

*(1,2) 表示训练阶段第一类与第二类为未知类别，其余组合以此类推。

表 3-5 合并 Houston 数据集测试数据分类结果 (均值 $\pm$ 标准差)Table 3-5 Testing data classification results (mean values $\pm$ standard deviation) on the merged Houston dataset

	(3,11)			(1,11)			(7,8)		
	CT-Mixer	MSSGU	VLHUC	CT-Mixer	MSSGU	VLHUC	CT-Mixer	MSSGU	VLHUC
	99.97 $\pm$ 0.04	99.73 $\pm$ 0.54	95.51 $\pm$ 1.90	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	63.63 $\pm$ 6.02	99.22 $\pm$ 0.55	99.48 $\pm$ 0.61	95.71 $\pm$ 1.47
	99.34 $\pm$ 0.47	99.85 $\pm$ 0.17	100.0 $\pm$ 0.00	99.34 $\pm$ 0.45	99.76 $\pm$ 0.20	100.0 $\pm$ 0.00	99.43 $\pm$ 0.43	99.82 $\pm$ 0.29	100.0 $\pm$ 0.00
	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	79.68 $\pm$ 1.58	99.15 $\pm$ 0.46	99.98 $\pm$ 0.03	88.42 $\pm$ 2.32	97.97 $\pm$ 2.05	100.0 $\pm$ 0.00	89.31 $\pm$ 3.03
	99.98 $\pm$ 0.03	99.92 $\pm$ 0.17	97.03 $\pm$ 2.56	99.95 $\pm$ 0.10	99.98 $\pm$ 0.03	98.88 $\pm$ 1.99	99.86 $\pm$ 0.13	99.92 $\pm$ 0.17	97.22 $\pm$ 2.40
	95.78 $\pm$ 4.38	98.51 $\pm$ 0.81	93.44 $\pm$ 2.39	95.84 $\pm$ 4.41	97.14 $\pm$ 4.14	97.79 $\pm$ 0.38	95.84 $\pm$ 4.41	98.51 $\pm$ 0.81	92.40 $\pm$ 3.42
	95.44 $\pm$ 2.16	97.82 $\pm$ 1.31	72.98 $\pm$ 2.38	94.82 $\pm$ 1.25	97.02 $\pm$ 1.77	73.81 $\pm$ 3.02	96.35 $\pm$ 1.95	97.74 $\pm$ 1.38	74.04 $\pm$ 3.29
	96.23 $\pm$ 2.23	92.03 $\pm$ 3.36	85.00 $\pm$ 2.48	96.10 $\pm$ 1.29	92.13 $\pm$ 5.63	84.41 $\pm$ 3.28	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	58.18 $\pm$ 9.03
	99.85 $\pm$ 0.31	99.79 $\pm$ 0.41	89.99 $\pm$ 4.12	100.0 $\pm$ 0.00	98.88 $\pm$ 1.34	90.56 $\pm$ 3.73	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	28.56 $\pm$ 0.89
	96.97 $\pm$ 1.67	100.0 $\pm$ 0.00	97.87 $\pm$ 1.57	98.07 $\pm$ 1.28	99.59 $\pm$ 0.82	97.86 $\pm$ 1.67	98.01 $\pm$ 1.46	99.61 $\pm$ 0.78	97.61 $\pm$ 1.53
	96.56 $\pm$ 2.78	97.38 $\pm$ 1.96	94.79 $\pm$ 1.46	98.50 $\pm$ 0.40	96.39 $\pm$ 3.44	95.16 $\pm$ 1.69	99.38 $\pm$ 0.47	98.19 $\pm$ 0.89	94.31 $\pm$ 1.63
	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	100.0 $\pm$ 0.00	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	0.70 $\pm$ 0.49	100.0 $\pm$ 0.00	100.0 $\pm$ 0.00	99.85 $\pm$ 0.20
	100.0 $\pm$ 0.00	99.97 $\pm$ 0.06	99.97 $\pm$ 0.06	99.94 $\pm$ 0.12	100.0 $\pm$ 0.00	99.94 $\pm$ 0.00	100.0 $\pm$ 0.00	99.97 $\pm$ 0.06	100.0 $\pm$ 0.00
OA (%)	86.51 $\pm$ 0.60	86.93 $\pm$ 0.23	89.80$\pm$0.68	77.96 $\pm$ 0.24	77.91 $\pm$ 0.60	82.55$\pm$1.26	81.52 $\pm$ 0.38	82.04 $\pm$ 0.21	83.16$\pm$0.59
AA (%)	81.68 $\pm$ 0.23	82.08 $\pm$ 0.29	92.19$\pm$0.40	81.81 $\pm$ 0.30	81.74 $\pm$ 0.82	82.60$\pm$0.57	82.17 $\pm$ 0.24	82.77 $\pm$ 0.15	85.60$\pm$0.70
K $\times$ 100	84.72 $\pm$ 0.67	85.19 $\pm$ 0.26	88.61$\pm$0.76	75.69 $\pm$ 0.26	75.56 $\pm$ 0.69	80.47$\pm$1.39	79.18 $\pm$ 0.41	79.65 $\pm$ 0.24	81.17$\pm$0.67
S(aa) (%)	98.01 $\pm$ 0.28	98.50$\pm$3.50	92.66 $\pm$ 0.33	98.17$\pm$0.37	98.09 $\pm$ 0.99	92.69 $\pm$ 0.57	98.61 $\pm$ 0.29	99.32$\pm$0.18	94.05 $\pm$ 0.55
U(aa) (%)	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	89.84$\pm$0.79	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	32.17$\pm$3.06	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	43.37$\pm$4.23
H(aa) (%)	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	91.23$\pm$0.55	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	47.67$\pm$3.37	0.00 $\pm$ 0.00	0.00 $\pm$ 0.00	59.24$\pm$3.81

屋顶 (第7类)”的组合上也表现不佳。结合原始图像分析，此处的“砂砾”实际指人工建筑而非松散砾石，其与“沥青屋顶”均偏离了 CLIP 接受的常规概念，进而引发误分类。在合并 Houston 数据集上，当“草地 (第1类)”与“网球场

表 3-6 QUH-Qingyun 数据集测试数据分类结果（均值 ± 标准差）

Table 3-6 Testing data classification results (mean values ± standard deviation) on the QUH-Qingyun dataset

	(1,4)			(5,6)			(3,6)		
	CT-Mixer	MSSGU	VLHUC	CT-Mixer	MSSGU	VLHUC	CT-Mixer	MSSGU	VLHUC
	0.00±0.00	0.00±0.00	87.41±0.97	99.20±0.17	99.70±0.11	98.92±0.27	98.74±0.29	99.51±0.18	98.18±0.47
	95.34±1.11	99.67±0.09	96.84±0.92	98.13±0.82	99.69±0.04	95.89±0.78	98.37±0.50	99.62±0.11	97.32±0.49
	55.27±1.52	82.76±4.07	75.35±1.96	66.13±8.42	97.23±0.84	86.51±3.25	0.00±0.00	0.00±0.00	89.17±1.22
	0.00±0.00	0.00±0.00	92.66±0.97	97.69±1.11	97.10±1.20	96.02±1.41	97.92±0.73	96.74±0.98	95.86±1.28
	97.81±0.57	99.17±0.23	98.16±0.13	0.00±0.00	0.00±0.00	89.34±0.68	96.72±0.56	99.29±0.09	98.34±0.27
	97.16±1.04	98.52±0.43	94.42±0.97	0.00±0.00	0.00±0.00	35.39±2.36	0.00±0.00	0.00±0.00	23.66±1.20
OA (%)	66.97±0.25	68.85±0.02	93.38±0.28	49.17±0.08	50.05±0.03	78.89±0.79	70.21±0.06	71.24±0.05	77.85±0.38
AA (%)	57.60±0.06	63.35±0.75	90.81±0.72	60.19±1.33	65.62±0.20	83.68±0.75	65.29±0.16	65.86±0.16	83.76±0.30
K×100	56.82±0.18	59.30±0.09	91.30±0.36	34.28±0.42	38.57±0.80	72.61±0.93	61.15±0.08	62.22±0.08	71.87±0.45
S(aa) (%)	86.40±0.10	95.03±0.11	91.19±0.77	90.29±0.99	98.43±0.31	94.34±0.64	97.94±0.14	98.79±0.24	97.43±0.31
U(aa) (%)	0.00±0.00	0.00±0.00	90.03±1.19	0.00±0.00	0.00±0.00	62.37±1.39	0.00±0.00	0.00±0.00	56.41±0.98
H(aa) (%)	0.00±0.00	0.00±0.00	90.60±0.79	0.00±0.00	0.00±0.00	75.08±1.11	0.00±0.00	0.00±0.00	71.45±0.76

（第 11 类）”同时作为未知类别时，模型难以对网球场进行分类，精度接近零；而当“砾石（第 3 类）”与“网球场（第 11 类）”为未知类别时，后者的识别精度可达 100%。这种差异主要源于草地与网球场在视觉上的相似性——二者在数据集中均呈现绿色，易产生混淆；而当草地不在未知类别集合中时，基于光谱的伪标签修正机制可利用二者独特的光谱特征实现区分。此外，当“道路（第 7 类）”与“高速路（第 8 类）”作为未知类别时，其精度相对较低，这可能是由于二者在光谱特征与类别语义上均高度相似，导致区分难度较大。QUH-Qingyun 数据集具有更高的空间分辨率与更规范的类别命名，伪标签精度更高，因此模型在未知类别上的表现更优。但仍存在挑战：例如，“沥青路（第 6 类）”通常占据较大面积，且在分割算法作用下呈现碎片化，导致空间上下文信息丢失，降低了 CLIP 的识别精度。如表所示，当沥青路在“（第 5 类，第 6 类）”与“（第 3 类，第 6 类）”等组合中作为未知类别时，其分类精度始终较低。

上述所有结果和分析中，可以推测：1）一般来说，高光谱图像的空间分辨率越高，模型的识别性能就越好；2）高光谱图像的类别标注越符合常规认知和日常使用习惯，模型的识别性能就越好；3）对于空间上视觉区分度低的地物，加入额外的专家知识（如光谱信息）将进一步提高模型的未知类学习能力。

3.3.3 消融实验与参数分析

本章所提方法包含多个核心模块，因此需通过消融实验与参数分析评估各模块的独立贡献。首先，我们评估多模型集成与基于 SAM 的增强效果，表 3-7 展示了不同模块组合下的伪标签精度，结果表明每个模块均对分类性能提升

产生积极影响。

表 3-7 不同模块的消融实验结果
Table 3-7 Ablation Experiments for Different Modules

V*	R*	S*	伪标签度量	Pavia University	合并 Houston	QUH-Qingyun
✓	×	×	OA (%)	42.84	32.24	33.67
			AA (%)	30.75	31.18	48.15
			K×100	30.06	24.57	23.05
×	✓	×	OA (%)	38.37	28.61	42.08
			AA (%)	24.38	35.70	52.97
			K×100	24.34	22.79	31.05
✓	✓	×	OA (%)	49.16	37.08	39.57
			AA (%)	32.65	37.56	53.56
			K×100	36.85	31.07	29.03
✓	×	✓	OA (%)	51.36	32.56	48.26
			AA (%)	39.84	31.14	59.12
			K×100	38.89	24.84	35.75
×	✓	✓	OA (%)	39.37	38.69	59.16
			AA (%)	24.36	51.99	48.96
			K×100	25.55	33.67	49.47
✓	✓	✓	OA (%)	51.68	43.17	61.11
			AA (%)	40.49	50.46	68.20
			K×100	39.38	37.83	51.45

* V: CLIP-ViT, R: CLIP-RSICD, S: SAM.

具体来说, 仅使用 CLIP-ViT 模块的基线配置 (R^* 激活) 在三个数据集上的所有指标 (OA、AA、K) 中表现最差, Pavia University、合并 Houston 和 QUH-Qingyun 数据集的 OA 分别为 42.84%、32.24% 和 33.67%, 这表明仅依赖 CLIP-ViT 所取得的效果有待提高。当集成 CLIP-RSICD 模块 (R^*) 后, 分类性能显著提升, 三个数据集的 OA 分别达到 49.16%、37.08% 和 39.57%, 这证明了引入遥感领域先验知识的积极作用。进一步添加 SAM 模块 (S^*) 可进一步增强性能, 完整模型配置, 即 V^* 、 R^* 、 S^* 均使用的条件下, 模型在三个数据集上分别取得最高的总体精度, 分别为 51.68%、43.17% 和 61.11%。这些结果验证了 CLIP-ViT、CLIP-RSICD 与 SAM 模块的协同作用能够进一步提升伪标签精度。值得注意的是, 移除 CLIP-ViT (仅保留 R^* 和 S^*) 会导致 OA 大幅下降。例如 Pavia University 数据集上所取得的 OA 降至 39.37%, 凸显了 CLIP-ViT 的核心作用。总体而言, 集成所有三个模块可最大化分类精度, 证明了各部分的有效性。

图 3-12 展示了三个数据集在不同的边缘扩展值 α 下的无监督伪标签精度，结果表明性能对 α 的选择具有明显依赖性。Pavia University 数据集在 α 为 0.1 时取得最高的平均精度 (51.68%)，而当 α 值为 0.05 和 0.3 时性能较低 (分别为 50.99% 和 51.11%)。类似地，QUH-Qingyun 数据集和合并 Houston2013 数据集上的结果表明 α 的最优值也为 0.1，OA 分别达到 43.71% 和 37.58%。这些结果表明， α 值取 0.1 通常适用于大多数数据集。




图 3-12 不同 α 值下伪标签的精度

Fig.3-12 Accuracies of pseudo-labels under different values of α

高光谱图像转换为 RGB 图像的方式有多种，不同转换方法会影响伪标签质量。本文通过消融实验比较了三种转换方法：1) 单波段选择：直接选择对应 R (620-750nm)、G (500-565nm)、B (400-450nm) 中心波长的三个波段；2) 范围平均：计算 R、G、B 典型波长范围内所有波段的均值生成各颜色通道；3) 高斯加权：对每个颜色范围内的波段分配高斯权重（以中心波长为峰值），再求和生成 RGB 通道。其结果如表 3-8 所示。从中可见，有效带宽较窄的方法（单波段选择和高斯加权）通常优于范围平均，这表明保留 R/G/B 中心波长附近相对集中的光谱信息更有利于视觉大模型的地物识别。单波段选择方法兼具简洁性、效率与足够的伪标签质量，因此被优先采用。

针对对于双 CLIP 模型结果的融合策略，本节进行试验比较简单平均与其他融合方法，具体来说包括：1) 熵加权：对每个 CLIP 模型的输出概率分布计算熵（预测不确定性指标，熵越低可靠性越高），并分配与熵成反比的权重（归一化至和为 1），优先考虑置信度更高的预测；2) 最大概率加权：以每个模型输出的最大概率值作为权重，强调类别确定性更强的预测；3) 乘积融合：计算双 CLIP 输出的乘积（而非求和），以放大高置信度预测之间的共识。结果如表 3-9 所示。

从中可以看出，简单平均在大多数指标上优于其他方法。我们注意到，尽管更复杂的融合策略可能进一步优化伪标签，但这验证本框架的核心思想（弥

合视觉大模型与高光谱分类之间的任务范式与知识鸿沟)并非必要。此类优化可在未来工作中探索,而无需改变广义零样本分类的基本流程,简单平均虽简洁但已具备有效性。

表 3-8 不同 RGB 输入生成方法的消融实验

Table 3-8 Ablation Experiment for Different RGB-Input Generation Methods

RGB 生成 方法	伪标签 精度	Pavia University	合并 Houston	QUH- Qingyun
单波段选择	OA (%)	51.68	43.17	61.11
	AA (%)	40.49	50.46	68.20
	K $\times$ 100	39.38	37.83	51.45
范围平均	OA (%)	46.69	30.66	54.60
	AA (%)	30.92	35.29	65.95
	K $\times$ 100	33.72	24.22	46.12
高斯 加权	OA (%)	53.38	38.90	59.34
	AA (%)	41.65	38.46	68.55
	K $\times$ 100	41.08	33.06	50.05

表 3-9 不同 CLIP 结果融合方法的消融实验

Table 3-9 Ablation experiments for different CLIPs' results fusion methods

融合 方法	伪标签 精度	Pavia University	合并 Houston	QUH- Qingyun
简单平均	OA (%)	51.68	43.17	61.11
	AA (%)	40.49	50.46	68.20
	K $\times$ 100	39.38	37.83	51.45
熵加权	OA (%)	51.68	40.12	60.84
	AA (%)	40.49	47.18	68.44
	K $\times$ 100	39.34	34.54	51.05
最大概率 加权	OA (%)	51.40	39.68	60.52
	AA (%)	40.20	46.97	67.72
	K $\times$ 100	39.11	34.05	50.74
乘积融合	OA (%)	51.55	42.82	58.83
	AA (%)	39.04	46.78	66.67
	K $\times$ 100	38.81	37.33	48.79

接下来,本节通过消融实验评估标签修正模块,表 3-10 记录了消融实验结果。与无标签修正(无)相比,引入标签修正(有)可持续提升分类性能。例如,在 Pavia University 数据集上,U(OA)从 49.20% 提升至 60.79%,H(OA)从 59.52% 提升至 71.17%;合并 Houston 数据集上,U(OA)从 29.77% 提升至 70.50%,H(OA)从 41.16% 提升至 78.28%;QUH-Qingyun 数据集上,U(OA)达到 69.63%,

H (OA) 也提升至 78.92%。这些结果证实标签修正模块可增强模型对未知类别的泛化能力, 也说明光谱信息的注入有助于弥合视觉语言模型同高光谱图像之间的领域知识差异。

表 3-10 标签修正模块的消融实验
Table 3-10 Ablation experiment for label correction

数据集	标签修正	S(oa) (%)	U(oa) (%)	H(oa) (%)	S(aa) (%)	U(aa) (%)	H(aa) (%)	OA (%)	AA (%)	K $\times$ 100
Pavia	无	75.70	44.41	51.66	66.19	40.54	46.33	70.46	60.49	61.88
University	有	96.79	60.79	71.17	94.52	57.16	68.38	90.35	86.22	87.34
合并	无	74.29	47.74	55.32	80.04	50.58	59.17	68.82	75.14	65.58
Houston2013	有	90.96	70.50	78.28	93.20	72.66	80.49	86.84	89.78	85.32
QUH-	无	72.45	62.51	63.79	77.16	68.55	71.06	68.69	74.29	60.51
Qingyun	有	96.17	69.63	78.92	93.55	74.26	82.17	87.04	87.12	83.17

此外, 图 3-13、图 3-14 和图 3-15 比较了所有未知类别组合下有无标签修正的分类结果。从中可见, 标签修正在多数未知类别组合下均提升了零样本分类性能: 一方面, 对于部分类别组合, 先前误分类的未知类别精度在标签修正后显著提升; 另一方面, 在部分初始零样本分类失败的场景中, 标签修正使模型能够为未知样本分配合理的预测。这些结果证明了标签修正对提升零样本分类性能的有效性。




图 3-13 Pavia University 数据集上有无标签校正下已知类、未知类与调和平均精度

Fig. 3-13 The mean seen, unseen, and harmonic accuracies with and without label correction on the Pavia University dataset

最后, 本节开展参数分析实验并简要分析损失权重 β 与 λ 的影响。图 3-16 展示了不同 β 值下的分类精度 (S (AA)、U (AA)、H (AA))。通常, β 值越大, 模型对伪标签的关注度越高。若 β 过大, 模型会过拟合于可能存在噪声的标签

而忽略监督训练结果；若 β 过小，模型可能无法充分学习未知类别，导致性能下降。 β 取0.5或1.0是多数评估指标下的良好选择。图3-17展示了不同 λ 值下的精度，总体而言， $\lambda = 0.05$ 适合大多数情况。




图3-14 合并 Houston2013 数据集上有无标签校正下已知类、未知类与调和平均精度
Fig. 3-14 The mean seen, unseen, and harmonic accuracies with and without label correction on the merged Houston2013 dataset




图3-15 QUH-Qingyun 数据集上有无标签校正下已知类、未知类与调和平均精度
Fig. 3-15 The mean seen, unseen, and harmonic accuracies with and without label correction on the QUH-Qingyun dataset

3.3.4 可视化结果

为更直观地验证所提方法在零样本场景下的分类性能，图3-18、图3-19和图3-20分别展示了三种数据集上不同方法的分类可视化结果。其中，图3-18中



 图 3-16 不同损失权重 β 下的精度


 Fig.3-16 Classification accuracies under different values of β

 图 3-17 不同损失权重 λ 下的精度

 Fig.3-17 Classification accuracies under different values of λ

的子图 (a)-(c) 对应未知类是第一类和第二类，子图 (d)-(f) 对应未知类是第五类和第八类，子图 (g)-(i) 对应未知类是第三类和第七类。同理，图 3-19 对应未知类为第三类和第十一类、第一类和第十一类以及第七类和第八类，图 3-20 对应未知类为第一类和第四类、第五类和第六类以及第三类和第六类，这与表 3-4、表 3-5 和表 3-6 相对应。

从定性分析结果可以明显看出，所提方法的未知类分类表现显著优于对比方法。以 Pavia University 数据集为例，当将第二类地物草地设定为未知类别时，缺乏未知类分类能力的传统方法极易将其误分为树木或裸土。此类误分类现象的核心原因在于，草地、树木与裸土在光谱特征和空间分布特征上存在高度相似性，传统方法仅依赖训练集的光谱和空间特征建模，无法对未参与训练的未知类别进行有效特征判别。与之相反，所提方法能够实现草地与相似地物类别的有效区分，这得益于视觉语言模型为模型提供了地物类别相关的语义先验知识，使模型能够突破训练集的类别限制，基于语义关联实现对未知类别的特征识别。上述定性结果进一步印证，所提方法通过融合视觉语言模型的语义信息，有效弥补了传统高光谱分类方法在零样本场景下的性能缺陷，让模型在面对未知类别时仍能保持较高的分类精度，实现了更精准、更鲁棒的高光谱图像地物