

哈尔滨工业大学

硕士学位论文开题报告

题 目：视觉语言模型辅助下多模态遥感图像分类方法研究

(学位论文)

学 院 电子与信息工程学院

学 科 信息与通信工程

导 师 何 欣

研 究 生 韩 晓

学 号 24S005019

开题报告日期 2025.09.14

研究生院制

目录

1. 课题来源及研究目的和意义	3
1.1 课题来源	3
1.2 研究目的和意义	3
2. 国内外研究现状及分析	4
2.1 经典多模态遥感图像分类方法研究现状	4
2.1.1 多模态遥感图像特征提取方法研究现状	5
2.1.2 多模态遥感图像特征融合方法研究现状	5
2.2 基于深度学习的多模态遥感图像分类研究现状	6
2.2.1 深度学习理论研究现状	6
2.2.2 深度学习在多模态遥感图像分类中的应用研究现状	7
2.3 未知类分类方法研究现状	8
2.3.1 高光谱图像中的未知类分类研究现状	8
2.3.2 遥感图像中的未知类分类研究现状	9
2.4 视觉语言模型研究现状	10
2.5 国内外文献综述简析	11
3. 主要研究内容及研究方案	12
3.1 主要研究内容	12
3.2 研究方案	14
3.2.1 基于 Transformer 的多模态遥感图像预训练方法研究	14
3.2.2 基于视觉语言模型的多模态遥感图像未知类分类方法研究	15
3.2.3 基于持续学习的多模态遥感图像未知类分类方法研究	17
4. 预期达到的目标	19
5. 已完成的研究工作	20
5.1 基于掩蔽 Transformer 的多模态遥感图像预训练方法	20
5.1.1 Transformer 模型概述	20
5.1.2 多模态掩蔽 Transformer 预训练方法	22
5.1.3 基于类别区分性和样本差异性的掩蔽 Transformer 预训练方法	24
5.2 实验部分	27
5.2.1 实验数据与实验设置	27
5.2.2 相关实验结果	31
6. 进度安排	35
7. 为完成课题所需的条件和经费	36
7.1 已具备的条件	36
7.2 所需的条件和经费	36
8. 研究过程中可能遇到的问题以及解决的措施	36
9. 参考文献	36

1. 课题来源及研究目的和意义

1.1 课题来源

该项目来源于黑龙江省自然基金项目。

1.2 研究目的和意义

作为遥感感知能力不断增强的重要体现，多模态遥感技术通过融合不同传感器（如高光谱、激光雷达、合成孔径雷达等）获取的异构信息，实现了从地物光谱特征、几何结构到空间分布等多角度、全方位的信息感知。多模态遥感数据往往具备互补特性，高光谱数据提供精细的光谱辨识能力，激光雷达数据则提供高精度的三维几何信息，合成孔径雷达在复杂气象条件下仍可稳定成像。多模态数据的融合分析不仅能够显著提升地物类别的可分性与分类精度，还拓展了遥感在城市管理、灾害评估、军事侦察等领域的应用能力，已成为遥感智能解译领域的研究热点[1]。

多模态遥感图像分类旨在充分利用不同模态的互补特征，实现更加全面、准确的地物分类[2]。尽管当前深度学习方法在多模态遥感分类任务中取得了显著成果，但大多数基于深度学习的多模态数据分类需要大量已标记样本且假设全部类别标记已知。这一假设与现实世界中的遥感应用存在较大差距。一方面，多模态遥感数据分类中获取训练样本的标签代价较高，在实际应用中未标记的样本数目多。另一方面，在实际遥感场景中，地物类型常常因自然变化或人为活动而不断演化，遥感系统常常需要面对从未标注过的新类别，即未知类。传统分类模型未能合理利用未标记样本，同时也未对未知类别的感知与分类能力进行探索。因此在实际遥感应用中，充分利用未标记样本进行预训练[3]，研究多模态遥感图像未知类分类具有重要实际意义。然而不同传感器获得的多模态数据具有差异性，以及存在于训练数据集之外的未知类带来了新的分类挑战：

1) 传统的多模态遥感图像分类模型通常建立在一个固定类别集合的假设之上，即认为测试图像中出现的所有地物类别在训练阶段都已经见过。这种做法在类别范围已知且稳定的情况下可以取得较好效果，但在真实的遥感应用中，分类阶段往往会出现训练集中未出现的新类别。此时，模型缺乏对未知类别的分类能力，往往会将其错误地归入已有类别，从而带来较高的误判风险。这不仅削弱了模型的泛化能力，也限制了其在动态场景中的应用价值。因此，需要研究模型应对未知类别的能力，从而实现未知类的准确分类。

2) 现有多模态遥感数据分类的方法都假设所有多模态遥感数据可一次性获取，并在统一的数据集上完成训练。但在实际应用中，遥感数据往往是按照时间顺序逐步获取的，由于获取周期长、覆盖范围广，经常会出现新类别。在这种情况下，传统模型在学

习新知识时容易遗忘已学过的类别特征，导致分类性能显著下降。针对该问题，需要研究能够在新增数据环境下持续学习的多模态遥感图像分类方法，即一方面保留和巩固从历史数据中获得的知识，另一方面能够快速适应新出现的类别，从而实现了对未知类的有效分类。

为应对上述问题，近年来 Transformer 结构被广泛引入多模态学习领域。相较于卷积神经网络（CNN），Transformer 以其强大的全局建模能力与跨模态对齐能力，可同时构建局部细节与全局上下文依赖，尤其适合建模不同模态之间的空间、光谱与结构特征关系[4]。其自注意力机制可动态捕捉多模态特征间的重要性权重，并对长距离依赖信息进行联合建模，具备更强的泛化能力。将 Transformer 引入多模态遥感图像分类，不仅可以提升特征融合质量，还可为识别未知类别提供更为灵活的表示空间。

本课题旨在研究视觉语言模型辅助下多模态遥感图像像素级分类，面向实际遥感应用中可能出现未知类别的场景，能够处理未知类分类。具体目标包括：设计基于预训练模型的多模态特征融合结构，通过在大规模数据上学习通用表征，充分发挥不同模态信息的互补优势；建立面向未知类别的分类机制，提升模型在面对训练中未见过类别时的分类性能；探索适用于多模态场景的持续学习策略，使得模型能够在新类别不断出现的情况下保持稳定表现，从而增强其在不同任务和区域中的泛化能力。综上所述，面对遥感应用中数据来源多样、地物类型变化复杂以及未知类别不断涌现的现实挑战，研究视觉语言模型辅助下多模态遥感图像像素级分类，不仅能够弥补传统方法在数据动态变化下的局限性，还能推动遥感智能分类技术向更加智能的方向发展，具有较强的理论价值与应用前景。

2. 国内外研究现状及分析

本课题涉及的相关研究得到越来越多国内外学者的关注，其中包含的相关理论和成果，对本课题的研究具有重要的推动作用，下面将从多模态遥感数据特征提取与融合、深度学习算法的应用、未知类分类方法以及视觉语言模型四个方面展开介绍和说明，为后续课题研究奠定基础。

2.1 经典多模态遥感图像分类方法研究现状

多模态遥感图像分类技术旨在利用不同遥感数据源间的信息互补性，以提升地物分类精度。传统多模态遥感图像分类方法大多围绕特征提取和特征融合两个方面展开研究。一方面，通过构建合适的特征表示方式来捕获各模态中的关键信息；另一方面，通过设计有效的融合策略将多模态特征加以整合，以发挥不同模态之间的互补优势。根据研究内容的不同，可以将其划分为特征提取方法和特征融合方法两个方面。

2.1.1 多模态遥感图像特征提取方法研究现状

传统的多模态遥感图像分类方法主要依赖于人工设计的特征提取器,从不同模态的数据中提取具有判别性的特征。为了适配不同类型的遥感数据,研究者通常会根据模态特性设计专门的特征提取器。例如,高光谱图像中每一个像素都包含连续且高维的光谱反射信息,早期研究尝试在光谱维度上进行特征提取,包括主成分分析、独立成分分析、线性判别分析等线性变换方法[5]。然而由于高光谱数据通常具有高度非线性的特征结构,基于线性变换的提取方式存在表达能力不足的问题。为此,研究者们引入了流形学习方法,如局部线性嵌入、拉普拉斯特征映射等,试图从非线性角度建模数据的内在结构[6]。此外,基于稀疏表示的光谱特征提取方法也随之涌现,通过将光谱向量表示为冗余字典中少量原子的稀疏组合,从而挖掘具有区分能力的潜在特征[7]。

为了丰富多模态遥感图像的特征表示,研究者逐渐将图像的空间信息引入特征提取中。常用的空间特征提取方法包括扩展形态学特征(Extended Morphological Profile, EMP)[8]、扩展形态学属性特征(Extended Morphological Attribute Profile, EMAP)[9]、小波变换[10]、Gabor 变换[11]、灰度共生矩阵[12]等。这些方法能够有效提取遥感图像的纹理、边缘和结构等高阶信息。

2.1.2 多模态遥感图像特征融合方法研究现状

在多模态遥感图像分类任务中,特征融合作为连接不同模态信息的关键环节,对最终分类性能起到决定性作用。由于不同模态在信息表达形式、语义侧重和特征分布上存在差异,同时又具有一定的互补性和冗余性。如何充分挖掘并融合跨模态的互补信息、抑制冗余干扰,从而提升地物识别的准确性,一直是研究的热点。

早期的融合方法大多采用特征拼接的方式,即在完成各模态独立的特征提取后,直接将其在维度上级联形成联合特征向量,并输入分类器进行判别。这种方式实现简单,但由于未考虑不同模态之间在尺度、分布及语义空间上的差异,常导致信息冗余和融合效率低下。为了克服这一问题,后续研究引入了更强的跨模态关联建模能力的融合策略。例如,Liao 等人提出了基于图结构的融合方法,通过构建多模态联合图,融合高光谱图像和激光雷达数据的形态学特征,从而增强特征融合[13]。Rasti 等人通过联合使用稀疏表示和低秩子空间建模来改进融合[14]。此外,考虑到不同的模态中包含的共有性和特异性信息,Hong 等人引入子空间正则化,提出了新的学习框架,将融合特征分解为跨模态共享的通用特征与模态特有的补充特征,在保留互补信息的同时有效降低了冗余干扰[15]。Pournemat 等人利用流形学习和半监督学习,进行跨模态对齐,抑制模态特有信息干扰[16]。

上述提取出的融合特征,通常需要借助分类器完成最终分类任务。常用的分类器包括支持向量机(Support Vector Machine, SVM)[17]、随机森林[18]等。

尽管传统多模态遥感图像分类方法已经取得显著进展,但其发展仍面临诸多挑战。

这些方法普遍依赖人工设计的特征提取器，难以自动捕获数据的深层语义信息，所提取的特征大多停留在底层或中层语义层次，难以应对遥感图像中场景多样性与复杂性。同时，模态间的信息冗余问题尚未得到有效解决，现有融合策略大多为静态固定，缺乏对模态互补关系的动态建模能力。此外，许多方法采用分阶段处理，特征提取、融合与分类过程相互割裂，缺乏端到端的整体优化能力。基于上述不足，为进一步提升多模态遥感图像的分类性能，有必要探索具备更强表征能力的自动特征提取方法。

2.2 基于深度学习的多模态遥感图像分类研究现状

随着深度学习方法在计算机视觉领域的广泛应用，其强大的特征提取能力也迅速拓展至遥感图像分析任务。与传统方法相比，深度学习方法无需依赖手工构造特征，而是能够端到端地从数据中自动学习具有判别性的深层表征。下面分别介绍深度学习以及其在多模态遥感图像分类中的研究现状。

2.2.1 深度学习理论研究现状

自从 2006 年 Hinton 等人提出使用逐层训练的方法训练深度置信网络（Deep Belief Network, DBN）以来，深度学习重新成为人工智能研究的热点[19]。深度学习通过多层的非线性变换对高维数据进行建模，能够自动从原始数据中提取出更加抽象和判别性强的特征，在计算机视觉、语音识别、自然语言处理等多个领域取得了巨大成功[20]。常见的深度学习模型包括堆栈自动编码器（Stacked Auto-Encoder, SAE）[21]、卷积神经网络（Convolutional Neural Network, CNN）[22]、循环神经网络（Recurrent Neural Network, RNN）[23]等。

卷积神经网络是一种深度前馈神经网络。其设计灵感源于上世纪中叶神经科学的发现，大脑视觉皮层采用分层处理机制，不同层级的神经元分别学习从边缘等简单特征到复杂抽象特征的不同表示。早在 1989 年，LeCun 等人提出了 LeNet-5 网络，用于手写数字识别[22]。后来 CNN 不断发展，Krizhevsky 等人在 2012 年提出了深度 CNN 结构 AlexNet，在 ImageNet 图像识别比赛中大幅超越传统方法，深度学习自此广泛应用于计算机视觉[24]。为了解决梯度消失问题，He 等人提出 ResNet 引入了残差连接机制，使得网络深度得以加深[25]。卷积神经网络利用局部连接和参数共享机制，有效降低了模型复杂度，减轻了过拟合和训练难度，增强了特征提取能力，逐渐成为计算机视觉中最广泛使用的网络模型。

随着研究深入，学者们逐步认识到传统 CNN 在建模长距离依赖关系方法存在不足。Transformer 是一种基于自注意力机制的序列模型，可以建模输入数据的长距离依赖关系，同时具备并行计算优势，大大提高计算效率。近年来，随着 Transformer 模型在自然语言处理领域（Natural Language Processing, NLP）的成功[26]，研究者开始探索其在视觉领域的应用，将 Transformer 逐步引入目标检测[27]、语义分割[28]、图像识别[29]等

任务。Vision Transformer (ViT)[29]通过将图像划分为序列处理,通过多头自注意力机制进行全局建模,在大规模数据集上展现出与传统 CNN 模型相当甚至更强的性能。随后, Swin Transformer[30]、Data-efficient image Transformer (DeiT) [31]、Pyramid Vision Transformer (PVT) [32]等多种改进架构陆续提出,分别在效率、分辨率适应性和多尺度建模等方面进行优化,使得 Transformer 模型逐渐成为计算机视觉领域与 CNN 并驾齐驱的重要方法。

随着深度学习对数据规模的依赖不断加剧,自监督学习成为解决标注数据稀缺问题的关键手段。自监督学习方法旨在从未标注数据中构造预训练任务,训练模型较高的特征提取能力,提升下游任务的性能。这些模型主要使用两种自监督学习目标来进行预训练以达到上述目的:对比学习(Contrastive Learning, CL)和掩蔽图像建模(Masked Image Modeling, MIM)。对比学习方法如 SimCLR[33]和 MoCo[34]通过最大化同一样本的不同视图之间的相似性和最小化不同样本的视图之间的相似性来学习图像的深层特征,推动了视觉预训练模型的进展。掩蔽图像建模如 MAE (Masked Autoencoder) 借鉴 BERT[35]的思路,旨在从掩蔽的输入图像中重建原始输入图像或特征[36]。这两种自监督训练方法可以从大规模无标注数据中获得对下游任务有益的特征表示,从而提高模型的精度与泛化能力。目前构建基于 Transformer 的通用模型已经成为深度学习领域的重要研究方向。

2.2.2 深度学习在多模态遥感图像分类中的应用研究现状

随着多模态遥感数据的不断丰富和深度学习理论的飞速发展,基于深度学习的多模态遥感图像分类方法已成为遥感智能分析的研究热点。相较于传统方法,深度学习能够自动提取多模态数据之间的高层次语义特征,有效建模模态间复杂的非线性关系,显著提升分类性能。

早期研究多采用卷积神经网络分别对不同模态进行特征提取,并通过简单拼接或融合模块进行信息整合。2017年,Chen 等人使用 CNN 进行双路特征提取,在融合阶段将不同模态的特征进行简单拼接[37]。Xu 等人在 2018 年提出基于双分支卷积神经网络模型,分别提取高光谱图像的空间-光谱特征和激光雷达数据的空间特征,再通过全连接层进行拼接,显著提升分类精度[38]。除了卷积神经网络外,Benedetti 等人设计了基于 RNN 和 CNN 的多模态分类模型,在多个数据集上有良好表现[39]。

随后,基于多尺度的特征融合逐渐成为主流方向。Song 等人通过融合不同尺度的空域和频域特征,从不同模态的图像中挖掘互补信息[40]。Feng 等人动态选择适当的尺寸特征,利用多尺度特征生成互补的联合特征,显著提高了分类精度[41]。此外,使用重建策略加强特征融合的方法也受到了研究者的青睐。Hong 等人[42]提出了一种编码器-解码器架构,对多模态输入进行重建。为了加深模态之间的交互,Xu 等人在模型中引入了交叉重建的策略,旨在让不同模态的特征更紧凑的融合在一起[43]。除此之外,图

卷积神经网络[44]、生成对抗网络[45]等网络模型在多模态遥感图像分类领域也有着广泛应用。

近年来,Transformer 在多模态遥感图像分类中的应用成为研究热点。得益于自注意力机制,Transformer 具备建模长距离依赖关系和跨模态交互的天然优势,展现出对复杂异构数据建模的巨大潜力。Xue 等人[46]和 Roy 等人[47]首次尝试通过改进 Transformer 架构以融合高光谱和 LiDAR 数据,分别从结构设计和注意力机制出发,提升模型的跨模态表达能力。考虑到模态间的异构性,Zhang 等人提出了一种基于局部特征交互的多模态融合架构,有效缓解了标准自注意力机制下对多模态信息同质化处理的问题[48]。为了有效提取多模态异构特征并减少信息损失,Zhao 等人将分数傅里叶变换与 Transformer 结合,显著加速 Transformer 架构,同时高效地学习有价值的上下文信息[49]。而 Yao 等人[50]提出了适用于多模态和跨模态场景的扩展 Transformer 模型,该方法不依赖具体模态类型,具备更强的适应性和实用性。此外,还有人探索将 Transformer 与 CNN 结合,以共同进行特征提取,充分发挥两种模型的优势。例如,[51]中使用了 CNN 进行局部空间特征学习,使用视觉 Transformer 进行全局光谱特征学习,同时提升了模型对局部信息和全局信息的感知能力。Zhao 等人将 CNN 与 Transformer 顺序构造,引入局部卷积感受野以提升空间特征捕获能力[52]。

此外,自监督学习与对比学习也逐渐在融合模型中应用。如 Hang 等人利用对比学习引导多模态网络学习光谱、空间与高度表征一致性,改善小样本下的融合鲁棒性[53]。上述研究均体现出深度学习在多模态遥感分类中融合机制的多样性、深层性和适用性。

2.3 未知类分类方法研究现状

随着遥感技术的迅速发展,遥感图像的获取维度日益丰富,催生了多模态遥感图像的广泛应用。然而,传统分类方法普遍依赖于封闭集假设,即训练与测试类别空间完全一致。在实际应用中,这一前提往往难以成立,因为随着数据获取和时间推移,新的地物类型会不断出现,导致模型对未知类缺乏分类和判别能力。这一问题促使学术界逐渐将研究重点转向未知类分类,希望在保持已知类识别精度的同时,具备对新类别的分类与区分能力。

2.3.1 高光谱图像中的未知类分类研究现状

随着高光谱成像技术的发展,其在农业监测、城市规划、环境检测等领域的应用日益广泛。然而大多数高光谱图像分类方法均假设训练集与测试集包含相同的类别,无法应对实际应用中可能出现的未知类别样本。这一问题促使研究者将未知类分类方法引入高光谱图像分类任务,即在测试阶段判别未知类别。

近年来,高光谱图像未知类分类研究不断取得进展,通过引入有效检测未知类别的策略,逐渐突破了传统闭集假设的限制。早期研究多基于在现有分类器中加入阈值判定

机制实现未知类检测，但此类方法通常对类内光谱差异和噪声较为敏感，导致在复杂遥感场景下性能下降。为克服这一不足，研究者提出了基于原型网络的方法，通过学习类别原型来提取判别性特征。例如，Du 等人提出了基于加权皮尔逊距离的特征不变性网络[54]和 Xie 等人提出了结合对比聚类模块的特征一致性网络[55]，都通过原型网络提取判别性特征，并引入新的度量方式提升已知类与未知类的区分能力。

除了基于原型网络的方法外，基于重建的框架也在高光谱未知类分类中展现出良好的效果。Yue 等人提出了一种光谱-空间潜在特征重建网络[56]通过联合重构光谱特征和空间纹理，保留了分辨未知类的有用信息，从而在不降低已知类分类精度的情况下提升了对未知类样本的判别能力。此外，Bi 等人将生成对抗网络与动态阈值结合[57]，通过生成判别器估计数据与已知分布的差异，提升未知类别检测的鲁棒性。随着网络架构的发展，更具表达能力的未知类分类模型不断涌现。例如，基于分数阶傅里叶变换的网络[58]能够拓展特征多样性并捕获光谱相位相关性，结合互逆点学习的类多层感知机网络[59]通过显示建模类别外空间，实现已知与未知类别的自适应边界扩展和动态阈值调整。这些创新方法在高维特征空间中拓展了决策边界，从而显著未知类检测率。

与此同时，元学习策略也被引入到高光谱未知类分类任务中，以提升模型的适应性和泛化性。例如，基于极值分布的元学习框架[60]结合 Weibull 分布建模和开集四元组损失，在保持类别流形拓扑一致性的同时，实现了对未知类别的精细化检测，并具备较强的跨数据集迁移能力。这类方法有效弥合了数据集特定调优与跨域泛化之间的差距，对遥感实际应用具有重要意义。

尽管高光谱图像的未知类分类方法取得了诸多进展，但仍主要停留在检测未知类别的层面，缺乏在无标注条件下进一步完成新类别识别的能力。因此，如何在保持已知类精度的同时，实现对未知类的有效分类与适应，仍是未来研究的核心难点。

2.3.2 遥感图像中的未知类分类研究现状

在遥感图像分类中，未知类问题不仅包括对未知类别的判别，还涉及在缺乏标注样本的情况下对其进行准确识别与分类。相比只进行已知类、未知类区分的方法，更具挑战性的是如何在测试阶段直接对未见过的类别完成有效分类，同时保证对已知类和未知类的均衡性能[61]。这一点对遥感任务尤为重要，因为实际场景下标注成本高昂，且地物类别随时间和环境不断变化。

解决未知类分类的关键在于构建能够连接已知类与未知类的语义桥梁，通常借助语义嵌入或辅助信息来实现。常见来源包括预定义属性、从大规模语料或维基百科训练得到的词向量等，这些语义信息将视觉特征和语义描述联系起来，促进知识迁移与泛化能力提升[62-64]。主流方法往往通过将视觉特征与语义嵌入投影到一个共同的潜在空间，使得样本能够围绕其对应的语义描述聚类；推理时通过在该空间内寻找最近的语义描述来赋予未知类样本类别标签[65]。为了提升效果，研究者在嵌入空间和正则化策略等方

面做了大量探索[66, 67]。与此同时,生成式方法(如生成对抗网络[68],变分自编码器[69]等)通过从语义描述合成类别视觉特征,将未知类分类问题重构为常规监督分类任务,从而显著缓解了数据不足带来的限制,这也成为了近年来的重要方向[70, 71]。

在遥感领域,对未知类的研究最早集中在场景分类任务上。早期工作借助 Word2Vec 等词向量构建类别间语义关系并据此进行知识传播与推断[72]。随后研究引入了半监督对齐策略以改善域间迁移与语义一致性[73]。针对遥感图像的特殊属性(如空间尺度变化、背景复杂性、多视角与多光谱信息),研究者提出了距离约束的语义自编码器[74]、利用预训练语言模型(如 Bidirectional Encoder Representations from Transformers, BERT)增强语义表征的 Transformer 框架[75]、以及基于生成对抗网络的视觉特征生成方法[76],均旨在缩小可见类与未知类之间的域差距并提升泛化能力。近年视觉语言模型(如 Contrastive Language-Image Pre-training, CLIP)在自然图像领域取得突破,随之被引入遥感领域研究,成为新的潜力方向[77]。例如, Xu 等人使用 CLIP 进行自动属性注释,并借助 Transformer 来关联局部图像区域并合并上下文信息以提升预测精度[78]。

尽管已有研究在遥感场景分类中展示了未知类分类的可行性,但其在多模态遥感图像中的应用仍面临挑战。多模态数据具有高光谱维度、模态差异和标注稀缺等特性,这对语义嵌入构建、视觉和语义映射策略以及模态间信息互补的利用提出了更高要求。目前相关研究仍较有限,且多集中在简单的语义对齐或基于词向量的直接映射,缺乏对光谱特征独特性和空间上下文协同建模的深入考虑。因此,未来工作亟需开发适配多模态特征结构的语义表示,建立更加稳健的已知类与未知类关系,并探索在实际应用中如何平衡二者的判别能力。

2.4 视觉语言模型研究现状

随着深度学习的快速发展,视觉语言模型已成为人工智能领域的重要研究方向。这类模型通过融合文本、图像模态数据,突破传统单模态系统的局限性,在跨模态理解、生成和推理任务中展现出显著优势。其核心目标在于通过联合建模图像与文本模态,学习到跨模态共享的语义表示,从而实现图文检索、视觉问答、图像生成等多种任务。根据视觉语言模型的学习范式,将其分为基于模态对齐和基于自然语言指令的两类方法。

早期,多模态大模型主要研究基于 Transformer 模型的模态对齐方法。Radford 等人开发的 CLIP 模型开创性地采用对比学习策略,在大规模图文对数据集上进行预训练,实现了语言-视觉语义对齐[77]。在此基础上,Alayrac 等人提出 Flamingo 模型,引入门控交叉注意力机制实现视觉特征到语言模型的渐进式融合,已显著提升少样本学习能力[79]。Li 等人提出的 BLIP 系列模型标志着多模态建模进入联合优化阶段[80],其改进版本 BLIP-2 创新性地引入 Q-Former 模块,构建可学习的视觉-语言查询接口,冻结视觉编码器和联合微调有效解决模态对齐与训练效率的平衡问题[81]。

随着大语言模型在文本理解与生成任务中的突破,视觉语言模型研究转向指令微调范式。该范式通过构建指令-响应对进行监督微调,使模型具备根据自然语言指令完成跨模态任务的能力。代表性的多模态大模型包括 LLaVA[82]、MiniGPT-4[83] 和 InstructBLIP[84]等。其中 LLaVA 通过线性投影层将 CLIP 视觉特征对齐至 LLM 词嵌入空间,再利用 GPT-4 生成的指令-响应数据微调语言模型。MiniGPT-4 引入通过特征对齐预训练及对话格式数据微调两阶段对齐策略解决视觉-语言模态失配问题。InstructBLIP 通过设计指令感知的特征提取器在视觉问答基准测试中已取得较好效果。最近,DeepSeek 系列模型的突破性进展将多模态研究推向新阶段。Liu 等人提出的 DeepSeek-V2 采用动态路由注意力机制,通过可微分门控网络实现跨模态计算路径的动态选择,根据输入内容的语义特征自动激活相关模态处理单元,为视觉语言模型的实用化部署提供了新思路[85]。

2.5 国内外文献综述简析

在多模态遥感图像处理技术中,分类能够充分利用不同模态数据的互补信息,旨在融合不同数据源的互补信息,实现对地物类别的精确分类与像素级标注,是遥感信息提取与应用的核心技术,长期以来受到遥感领域的广泛关注。

早期的多模态遥感图像分类主要依赖特征工程,通过主成分分析、独立成分分析、流形学习等方法提取高光谱数据的光谱特征,并结合形态学特征、Gabor 滤波、小波变换等空间特征提取技术。在特征融合方面,早期多采用特征拼接,而后发展出基于图模型、子空间正则化、流形对齐等策略实现跨模态信息整合,提升了信息互补性与判别能力。最终利用 K 近邻、随机森林或支持向量机等分类器完成分类。这类经典方法实现简单,特征可解释性强,但高度依赖人工设计,融合策略静态固定,且特征提取与分类过程分离,限制了跨模态特征的表达能力与泛化性能。

随着深度学习的发展,研究者开始探索端到端的多模态遥感分类框架,利用卷积神经网络、循环神经网络等自动从原始数据中学习高层次特征,显著增强了非线性关系建模能力。融合策略也从单一的特征拼接发展到多尺度特征融合、跨模态重建、图神经网络与生成对抗网络等多样化方法。近年来,Transformer 因其强大的自注意力机制能够同时建模长距离空间依赖与光谱相关性,被逐渐引入多模态遥感分类任务,并与 CNN 结合形成混合架构,实现了对局部细节与全局依赖的兼顾;同时,自监督与对比学习为小样本和无标注场景提供了有效的预训练手段。然而,由于 Transformer 缺乏归纳偏置,其在样本有限的情况下性能受限,在多模态遥感场景下需对预训练方法应用进行深入研究。

尽管深度学习方法在多模态遥感分类中取得了显著性能提升,但现有研究大多假设训练与测试数据类别一致,忽视了实际应用中会不断出现新的未知类别。因此,如何在

保证已知类别识别精度的同时,有效发现并区分未知类别,已成为亟需解决的重要问题。针对未知类分类,现有工作主要有两类思路:一类方法侧重在测试阶段判别未知类别,常通过设置判别阈值、引入特征度量网络或结合特征重建与对抗学习来提高已知类与未知类之间的区分能力;另一类方法则尝试在缺乏标注样本的条件下对新类别进行直接分类,通常借助语义嵌入或生成模型来实现从已知类别向未知类别的知识迁移。在遥感场景分类领域,已有基于词向量的语义关系建模、语义自编码器的表征学习、预训练语言模型的语义增强、生成对抗网络的特征生成以及视觉语言模型的联合建模等探索,为未知类分类提供了多种技术路径。尽管未知类分类已经在遥感领域进行了初步研究,但是针对多模态遥感图像的未知类分类研究处于起步阶段,仍然存在以下问题:

(1) 近年来,多模态遥感图像分类方法已经得到广泛研究,SAR、LiDAR 和高光谱等数据的融合在一定程度上提升了分类精度。然而,这类方法仍面临跨模态语义对齐和互补信息挖潜不充分等问题。同时,大规模标注样本的获取代价高昂,使得现有方法难以充分利用海量无标注的遥感数据。此外,传统卷积神经网络在感受野与全局信息建模方面存在瓶颈,难以有效捕捉遥感影像中的长距离依赖与跨尺度关系。因此需要研究基于 Transformer 的多模态遥感图像预训练方法,为后续的未知类分类提供更加稳健的特征表示。

(2) 现有的多模态遥感图像分类方法缺少未知类分类的方法。这些方法都是以测试集的所有地物类别包含在训练阶段中为前提,其分类器的输出类别空间固定于训练时的样本空间。当测试阶段出现未见类别时,模型会将其归入已知类别,无法将其正确分类。与此同时,遥感领域的未知类分类研究多局限于单模态任务上,缺乏针对多模态遥感数据的系统性方法探索,因此,对多模态遥感领域的未知类分类进行研究,目标在于构建已知类与未知类之间更加稳健的关联机制,从而实现对未知类的有效分类。

(3) 现有方法通常将分类任务视为一次性学习过程,缺乏持续学习能力,一旦出现新的未知类,往往需要重新训练。由于遥感数据规模庞大、获取与处理成本高,重新训练不仅效率低下,而且还可能导致原有类别精度下降。此外,多模态遥感数据的复杂性进一步加剧了这一问题。遥感数据不仅覆盖范围广、获取周期长,而且往往以分批次、跨时间和跨区域的方式积累,难以在一次采集和标注中覆盖所有潜在类别。这意味着新的未知类别会不断涌现,模型必须具备动态适应的能力。因此,需要研究如何将持续学习和未知类分类相结合,构建能够扩展类别空间并保持稳定性能的多模态遥感分类框架。

3. 主要研究内容及研究方案

3.1 主要研究内容

针对多模态遥感图像在实际分类应用中面临的对标注样本依赖性强、模态间特征差

异显著以及在实际应用下难以有效识别未知类别等挑战,本课题将深入研究视觉语言模型辅助下多模态遥感图像像素级分类,旨在提升模型在多模态数据条件下的跨模态融合能力与未知类别识别能力,并增强在动态环境中的持续适应性。研究内容分为三个方面:第一部分主要研究基于 Transformer 的多模态遥感图像预训练方法,为多模态数据融合和跨模态特征建模提供坚实的特征基础,为后续未知类分类打下基础;第二部分主要研究基于视觉语言模型的多模态遥感图像未知类分类方法,利用视觉语言模型的先验知识解决多模态遥感图像中未见类别的分类问题。第三部分在第二部分的基础上,针对遥感数据规模庞大、类别持续增加的实际情况,主要研究基于持续学习的多模态遥感图像未知类分类方法,以确保在新的未知类别不断出现的情况下,模型保持分类性能的稳定性,并实现对新的未知类别的分类。

(1) 基于 Transformer 的多模态遥感图像预训练方法

针对传统多模态遥感图像分类方法(如 CNN 方法)在建模模态间的长距离依赖关系方面存在不足,本课题首先研究基于 Transformer 模型的多模态遥感图像特征融合方法,设计适用于不同模态(如高光谱、LiDAR、SAR、光学等)特征提取的跨模态 Transformer 结构。为了解决 Transformer 缺少局部归纳偏置导致分类精度低的问题,本课题将研究基于跨模态掩蔽重建任务的预训练方法,通过在不同模态数据间进行联合重建,使得 Transformer 模型学习到模态间的互补特征关系,从而同时获得局部建模能力和跨模态关联建模能力。

(2) 基于视觉语言模型的多模态遥感图像未知类分类方法

现有多模态遥感图像分类方法普遍假设测试数据中所有类别均在训练阶段出现,因为无法有效识别训练阶段中未出现的新类别。针对这一问题,本课题将研究把对象级分类的视觉语言模型迁移至像素级多模态遥感图像分类的技术路线,探索利用预训练视觉语言模型的先验知识,在多模态特征空间中建立已知类别、未知类别与图像样本特征之间的映射关系,从而在保持已知类别高精度分类的同时,实现未知类别的有效分类。

(3) 基于持续学习的多模态遥感图像未知类分类方法

现有多模态遥感图像分类方法在面对持续到来的新任务和新类别时,往往假设训练阶段能够覆盖所有目标类别,这使得模型在实际动态环境中难以适应不断扩展的类别集合。同时,传统方法在学习新类别的过程中容易产生灾难性遗忘,导致对已学类别的分类精度显著下降,从而限制了模型在真实遥感应用中的长期有效性。针对上述问题,本课题将研究基于持续学习的多模态遥感图像未知类分类方法。具体而言,将在已有的视觉语言模型多模态分类框架基础上,引入混合专家适配器实现模型动态扩展,并结合激活-冻结平衡策略,在持续任务中保持旧知识的判别能力,同时高效学习新未知类别特征,对分阶段到来的未知类进行持续分类。该方法旨在构建能够在任务序列中不断自适应的分类模型,实现已知类的稳健分类与未知类的有效持续学习。

3.2 研究方案




图 3-1 总体研究方案

本课题的总体研究方案，包括基于 Transformer 的多模态遥感图像预训练方法、基于视觉语言模型的多模态遥感图像未知类分类方法和基于持续学习的多模态遥感图像未知类分类方法三部分，如图 3-1 所示。第一部分，采用掩蔽图像重建策略对 Transformer 进行预训练，为后续未知类分类提供特征提取能力强的 Transformer 模型；第二部分利用语言视觉模型解决多模态遥感图像的未知类分类问题，为基于持续学习的未知类差异提供研究基础；最后对多模态遥感图像持续学习分类问题进行研究。

3.2.1 基于 Transformer 的多模态遥感图像预训练方法研究

在多模态遥感图像特征提取方法中，卷积神经网络采用局部连接和权值共享的方式，能够有效进行特征提取，在早期研究中占据主导地位。然而，基于 CNN 的多模态遥感图像分类方法由于卷积核感受野受限，难以对不同模态数据中长程依赖关系进行有效建模。针对跨模态和跨场景条件下复杂的空间分布和数据差异，需要同时考虑局部和全局的像素依赖关系，建立跨模态像素乃至地物之间的空间上下文关系。Transformer 模型的出现为长距离依赖建模与全局特征提取提供了强有力的工具。因此，本课题将以 Transformer 为基础，实现多模态遥感图像的局部和长程特征联合提取，为后续未知类分类与持续学习任务奠定特征提取基础。

多模态遥感数据不仅在空间和光谱特征上差异显著，还具有不同的噪声特性和数据分辨率差异。传统视觉 Transformer 在输入时大多将图像划分为空间块作为序列输入，主要依赖空间自注意力机制，而忽视了不同模态特征的互补性和特有属性。因此，直接应用这些模型难以在多模态遥感特征提取中，难以获得理想的实验精度。




图 3-2 基于 Transformer 的多模态遥感图像预训练流程示意图

为了充分利用多模态遥感图像中的空间-光谱信息，本课题拟在空间块划分之前，先对光谱信息进行处理，设计一个光谱信息聚合模块，对不同模态数据的光谱特征进行初步提取，确保每个空间块中蕴含丰富的光谱信息，使后续 Transformer 模型能够高效提取融合特征。与此同时，遥感图像具有局部空间一致性，即相近空间位置的像素更可能属于同一地物类别。本课题还将研究基于掩蔽重建的多模态遥感图像预训练方法，通过空间掩蔽任务，使 Transformer 从掩蔽的图像中恢复原始信息，使得 Transformer 在预训练阶段提升对局部空间信息的关注，提升模型学习局部与模态的独立特征。

然而，单纯依靠掩蔽重建获得的特征虽然具备一定判别能力，但主要关注输入样本的语义信息，其对于不同训练样本的区分性不足，难以直接满足分类需求。因此，本课题将引入实例对比学习与类间判别监督两种机制，将判别性特征提取能力注入 Transformer 的预训练阶段，获得既具有全局建模能力又具有强判别性的多模态 Transformer 特征提取模型，整体预训练流程如图 3-2 所示。其中实例对比学习用于区分不同样本，类间判别监督用于强调不同类别间的差异性。该模型将在后续未知类分类与持续学习阶段通过微调的方法进行应用。

3.2.2 基于视觉语言模型的多模态遥感图像未知类分类方法研究

在多模态遥感图像未知类分类任务中，核心挑战在于在缺乏训练样本的情况下，如何获取未知类的先验知识并建立已知类与未知类的语义关联。现有多模态遥感数据面临标注不统一、类别规模有限、跨模态特征分布差异显著等问题，使得常规未知类分类方法难以直接适用。为了实现未知类分类，需要解决 1) 已知类别和多模态样本特征之间的映射关系，2) 未知类别与已知类别在特征空间中的关联，从而获得未知类别的特征表示和语义信息。

针对上述问题，本章提出基于视觉语言模型的多模态遥感图像未知类分类框架 (MRS-VLM-Tr)，如图 3-3 所示，该框架利用预训练视觉语言模型中蕴含的丰富语义知识，通过伪标签获取机制引入未知类别的先验信息，并结合监督训练获得对已有类别的精确分类能力。整体框架主要包括伪标签获取阶段和全局训练阶段。




图 3-3 基于视觉语言模型的多模态遥感图像未知类分类流程示意图

在伪标签获取阶段，本课题采用 CLIP 模型作为核心的视觉语言模型。CLIP 由图像编码器 f_I 和文本编码器 f_T 组成，能够将图像和文本投影到同一语义嵌入空间中，并通过对齐大规模图文对进行预训练获得强大的语义关联能力。在训练阶段，对于给定的 N 个图文对，CLIP 计算出一个相似性矩阵，其中每一行表示一张图片与所有 N 个文本描述的相似度。CLIP 通过最大化正样本对的相似度，最小化负样本对的相似度。在推理阶段，对于一个输入图像 x 和 K 个候选类别，首先将类别名嵌入到固定模板（如 “an image of a [CLASS]”）中生成文本描述 $\{y_i^T\}_{i=1}^K$ ，并通过图像和文本编码器得到各类别的图像和文本向量：

$$v_I = f_I(x) \quad (3-1)$$

$$v_T^i = f_T(y_i^T), i = 1, \dots, K \quad (3-2)$$

随后计算图像向量与各类别文本向量之间的余弦相似度，并通过 Softmax 归一化得到各类别的预测概率，预测标签为概率最高的类别：

$$p^i = \frac{\exp(\{v_I, v_T^i\}/\tau)}{\sum_{j=1}^K \exp(\{v_I, v_T^j\}/\tau)} \quad (3-3)$$

其中 $\{, \}$ 表示余弦相似度， τ 作为超参数在训练过程中学习。上述的推理过程可以简化为：

$$P \in \mathbb{R}^K = \text{CLIP}(x, \{y_i^T\}_{i=1}^K) \quad (3-4)$$

然而，CLIP 是基于整幅图像进行建模的，而多模态遥感图像分类任务是基于像素

级别，因此需要解决图像级语义到像素级标签的转化问题。为此，本章提出一种基于超像素的伪标签生成策略，以实现语义的平滑过渡。具体步骤如下：首先将多模态遥感数据配准到统一的空间参考框架；然后利用超像素分割算法将 HSI 图像 $X^{HSI} \in \mathbb{R}^{H \times W \times B}$ 和 LiDAR 图像 $X^{LiDAR} \in \mathbb{R}^{H \times W \times 1}$ 所对应的 RGB 图像分割成 N 个超像素块：

$$(s_i^{HSI})_{i=1}^N = Seg(X^{HSI}), (s_i^{LiDAR})_{i=1}^N = Seg(X^{LiDAR}) \quad (3-5)$$

由于每个超像素区域 s_i^{HSI} 和 s_i^{LiDAR} 并非规则形式，需要将其裁切成矩形图像块 a_i^{HSI} 和 a_i^{LiDAR} 。接着，将构造好的类别文本描述与裁剪的图像块一同输入 CLIP 模型，得到该区域的双模态类别预测标签，对双模态的类别预测标签取均值，得到该区域最终的类别预测标签：

$$P_i^{HSI} = CLIP(a_i^{HSI}, \{y_i^T\}_{i=1}^K), P_i^{LiDAR} = CLIP(a_i^{LiDAR}, \{y_i^T\}_{i=1}^K) \quad (3-6)$$

$$P_i = (P_i^{HSI} + P_i^{LiDAR})/2 \quad (3-7)$$

将 P_i 分配给超像素区域 s_i 内的所有像素，最终形成整幅图像的伪标签图 $P \in \mathbb{R}^{H \times W \times K}$ 。

在全球训练阶段，首先利用 CLIP 的语义关联能力为图像区域生成全局伪标签，从而将 CLIP 中蕴含的语义先验转换成未知类的初步知识。训练时采用复合损失，一方面用监督分类损失在已标注的已知类样本上优化模型，使其保持已知类的高精度；另一方面用伪标签损失对模型输出与 CLIP 生成的全局伪标签进行对齐，以引入未知类的语义信息。由于训练集仅包含已知类标签，为防止模型偏向已知类、错误将未知样本归入已知类，增加了类别平衡约束以抑制对常见类别的过拟合。总体上，监督分类损失由真实标签计算得到，伪标签损失由模型预测与 CLIP 伪标签之间的差异计算得到，三者加权共同优化以兼顾已知类精度与未知类识别能力。

3.2.3 基于持续学习的多模态遥感图像未知类分类方法研究


在多模态遥感图像分类任务中，现实场景常常存在数据逐步到达、类别持续增加的情况，模型需要在保留以往所学习旧知识的前提下学习新类别知识，这正是持续学习的研究目标。然而，跨模态数据在特征分布上的差异，使得持续学习在多模态研究领域面临灾难性遗忘与类别不平衡的双重挑战，尤其是在未知类的类别信息完全缺失的条件下。持续学习在多模态遥感中的主要难点包括：

- 1) 灾难性遗忘：新任务训练导致已有知识被覆盖或丢失。
- 2) 未知类分类：需要在新出现的类别上实现分类能力。

针对上述问题，本章在研究内容二基于视觉语言模型的多模态遥感未知类分类框架 (MRS-VLM-Tr) 的基础上，引入持续学习机制，构建具有未知类分类能力的多模态遥感持续学习框架 (MRS-VLM-CL)。该框架通过混合专家适配器 (Mixer-of-Experts Adapters, MoE Adapters) 实现动态扩展，结合视觉语言模型的先验能力与持续学习的记忆保持机制，在保持对已知类别的分类精度的前提下，实现对未知类别的高适应性和

持续学习。

对于逐步到达的数据流（任务序列） $\{\mathcal{T}^t\}_{t=1}^T$ ，持续学习通过顺序访问和学习每个任务 $\mathcal{T}^t = \{\mathcal{D}^t, \mathcal{C}^t\}$ ，其中 $\mathcal{D}^t = \{\mathcal{I}_i^t, \mathcal{Y}_i^t\}_{i=1}^{N^t}$ 表示在第 t 个阶段接收到的多模态遥感数据， $\mathcal{I}_i^t$ 表示输入图像， $\mathcal{Y}_i^t \in \mathcal{C}^t$ 为对应的类标签， N^t 表示样本数。类别集合 $\mathcal{C}^t = \{c_j^t\}_{j=1}^{M^t}$ 包含 $\mathcal{T}^t$ 内的类名，总共有 M^t 个类。本课题研究的持续学习属于类持续学习，每个任务的类别关系为 $\mathcal{C}^j \subset \mathcal{C}^i, j < i$ ，即类别的数量是按照类别顺序而增加的，而且旧任务所包含的类别是新任务包含类别的子集，类持续学习需要区分之前出现的所有类别 $\cup_{i=1}^t \mathcal{C}^i$ 。



在方法设计上，本部分首先在前面未知类分类方法的基础上，实现未知类的分类，再对后续任务到来的新未知类别进行持续学习。持续学习要求在任务序列中显式或隐式地保持历史任务知识，并有效适应新任务特征分布的变化，避免遗忘已学类别的判别信息。为此，本课题引入了动态扩展的 MoE Adapters 来增强模型的增量适应性与参数利用率，并结合激活-冻结平衡策略来约束 MoE 结构，在任务内知识获取和任务间知识共享

之间取得平衡，其中这些专家可以是多层感知机也可以是注意力头。其基本框架如图 3-4 所示，主要由预训练的多模态遥感图像特征提取网络和 MoE Adapters 组成。

MoE 模块包含 N_E 个预定义专家 $\{\varepsilon_i\}_{i=1}^{N_E}$ 多个任务专属路径。对于当前任务 $\mathcal{T}^t$ ，仅新增一个对应的路径 $\mathcal{R}^t, t \in [1, T]$ ，该路径根据输入特征分配门控权重，对专家输出进行加权融合。在持续学习阶段，将所有 Transformer 块的参数进行冻结，MoE 模块在所有 Transformer 块中实现。具体来说，在每个 Transformer 块中，多头注意力机制输出后的特征 $x^t \in \mathbb{R}^{n \times d}$ 被传递给 MoE 中的所有专家。然后应用于特定任务的路径 $\mathcal{R}^t$ 通过加权求和来融合专家们的输出，输出表示为：

$$y^t = \sum_{i=1}^{N_E} W_i^t \varepsilon_i(x^t) \quad (3-8)$$

其中 $W^t = \{W_i^t\}_{i=1}^{N_E}$ 表示由 $\mathcal{R}^t$ 分配的門控权重，决定每个专家的贡献。 x^t 表示第 t 个任务处理的特征， y^t 是 MoE 适配器对应的输出，与 x^t 的形状相匹配。門控权重 W^t 的计算如下：

$$W^t = \text{Softmax}(\text{Topk}(\mathcal{R}^t(c^t))) \quad (3-9)$$

其中 $\mathcal{R}^t$ 将类别信息 c^t 映射为一维向量， $\text{Topk}(\cdot)$ 函数选择 k 个最相关的专家，同时将其余专家设置为负无穷。 $\text{Softmax}(\cdot)$ 函数将这些权重归一化，以强调所选专家的贡献。

在训练阶段，通过简单的反向传播来训练 MoE，由激活-冻结平衡策略引导，以增强专家的任务内知识学习和任务间协作。具体来说，在对旧任务进行训练后，计算其路径输出的門控权重。然后，在随后的任务训练中，最活跃的专家被冻结，以保存特定于任务的知识。通过这种方式，当面对新任务时，相应的路径能够访问冻结的专家以利用来自历史任务的可共享知识，并且优化未冻结的专家以获取新任务的特定信息。如图 3-5 所示，路径可在训练中灵活选择：(a) 仅未利用的专家；(b) 同时利用新专家与部分旧专家；(c) 仅利用旧任务专家，从而实现新知识与已有记忆的有效融合与迁移。




图 3-5 路径激活 MoE 示意图

4. 预期达到的目标

(1) 通过设计适用于多模态遥感数据的跨模态 Transformer 结构，并引入跨模态掩蔽重建与对比学习机制，探索同时兼具全局建模能力与判别性的特征提取模型，实现对

高光谱、LiDAR、SAR 等多模态数据的高效融合和表征。基于掩蔽重建的预训练方法，构建跨模态视觉 Transformer 模型来完成多模态遥感数据的分类问题，为后续未知类分类与持续学习奠定坚实的特征基础。

(2) 通过将预训练视觉语言模型（如 CLIP）迁移至像素级分类任务，并结合超像素伪标签生成与知识蒸馏方法，建立已知类、未知类与多模态图像特征之间的语义映射关系。预期实现在缺乏训练样本的情况下对未知类别的有效分类，同时保证已知类别的高精度分类性能，提升模型的语义泛化与跨模态适应能力。

(3) 基于视觉语言模型的语义先验与混合专家适配器（MoE Adapters）的动态扩展机制，结合激活-冻结平衡策略，实现对新未知类别的持续学习与对旧知识的长期保持。预期能够构建一个持续学习框架，使模型在动态环境中不断适应新任务和新类别的同时，保持对已知类别的识别精度，并具备对未知类别的持续学习能力，从而在真实应用场景中实现更可靠和持久的多模态遥感图像分类性能。

5. 已完成的研究工作

5.1 基于掩蔽 Transformer 的多模态遥感图像预训练方法

本节主要研究基于跨模态 Transformer 的多模态遥感图像预训练方法研究，为后续基于视觉语言模型的多模态遥感图像未知类分类方法研究奠定基础。

多模态遥感数据在成像机理和特征分布上存在显著差异，例如高光谱影像包含丰富光谱信息，LiDAR 提供精确空间高程信息，SAR 具备全天候成像能力，而光学影像反映地物纹理与结构。不同模态之间存在天然的互补性，但传统方法难以充分挖掘模态间关联，导致特征融合效果有限。Transformer 模型在全局建模上具有优势，但缺乏局部归纳偏置，直接应用于多模态遥感图像时容易忽略局部空间一致性和模态间互补特征，从而影响跨模态特征提取与分类性能。

针对上述问题，本课题提出了基于跨模态掩蔽的 Transformer 预训练方法。该方法通过在跨模态特征空间中按照一定比例随机掩蔽部分空间块，并利用未掩蔽区域和其他模态的互补信息恢复缺失内容，从而迫使模型学习不同模态之间的互补特征以及空间局部关联特征。

5.1.1 Transformer 模型概述

视觉 Transformer (ViT) 是一类深度学习模型，通过自注意力机制 (Self-Attention) 对图像输入进行特征建模。假设输入的图像为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ ，其中 H 为图像高度， W 为图像宽度， C 为波段数或通道数。

在 Transformer 中，图像 $\mathbf{X}$ 首先被划分为 $P \times P \times C$ 的不重叠图像块，每个图像块展平为序列 $\{\mathbf{x}_n \in \mathbb{R}^{P^2 C}\}_{n=1}^N$ ，其中 $N = HW/P^2$ 为图像块数量。随后，通过可学习得线性映

射矩阵 $E \in \mathbb{R}^{P^2 C \times D}$ 将每个图像块投影到 D 维特征空间，得到初始标记向量 $\bar{\mathbf{x}}_n$ 。为了保留空间位置信息，引入可学习的位置编码 $\mathbf{p}_n \in \mathbb{R}^D$ ，将其与标记向量相加：

$$\mathbf{z}_n \in \mathbb{R}^D = \mathbf{p}_n + \bar{\mathbf{x}}_n \quad (5-1)$$

然后，将标记向量序列 $\{\mathbf{z}_n\}_{n=1}^N$ 与一个类标记向量 $\mathbf{z}_{cls}$ 拼接，形成了 Transformer 编码器的输入：

$$\mathbf{Z}^{(0)} \in \mathbb{R}^{(N+1) \times D} = [\mathbf{z}_{cls}; \mathbf{z}_1; \mathbf{z}_2; \dots; \mathbf{z}_N] \quad (5-2)$$

Transformer 编码器由 L 个编码块堆叠而成，每个编码块包含多头自注意力层（Multi-Head Self-Attention, MHSA）带 GELU 激活函数的多层感知机（Multi-Layer Perception, MLP）以及归一化层（Layer Normalization, LN）。第 l 个编码块的特征提取过程可表述为：

$$\mathbf{H}^{(l)} = \text{MHSA}(\text{LN}(\mathbf{Z}^{(l-1)})) + \mathbf{Z}^{(l-1)}, \quad l = 1, \dots, L \quad (5-3)$$

$$\mathbf{Z}^{(l)} = \text{MHSA}(\text{LN}(\mathbf{H}^{(l)})) + \mathbf{H}^{(l)}, \quad l = 1, \dots, L \quad (5-4)$$




图 5-1 自注意力机制计算示意图

如图 5-1 所示，在自注意力机制中，每个编码块首先生成查询（Query）、键（Key）和值（Value）张量：

$$\mathbf{Q}^{(l)} = \text{LN}(\mathbf{Z}^{(l-1)})\mathbf{W}_Q^{(l)} \quad (5-5)$$

$$\mathbf{K}^{(l)} = \text{LN}(\mathbf{Z}^{(l-1)})\mathbf{W}_K^{(l)} \quad (5-6)$$

$$\mathbf{V}^{(l)} = \text{LN}(\mathbf{Z}^{(l-1)})\mathbf{W}_V^{(l)} \quad (5-7)$$

其中， $\mathbf{W}_Q^{(l)}$ 、 $\mathbf{W}_K^{(l)}$ 和 $\mathbf{W}_V^{(l)}$ 分别表示自注意力机制中的查询、键和值投影矩阵。那么第 l 个编码块的自注意力计算可表示为：

$$\mathbf{A}^{(l)} = \text{Softmax}(\frac{\mathbf{Q}^{(l)}\mathbf{K}^{(l)T}}{\sqrt{D}})\mathbf{V}^{(l)} \quad (5-8)$$

$$\mathbf{H}^{(l)} = \mathbf{A}^{(l)} \mathbf{W}_0^{(l)} \quad (5-9)$$

其中, $\mathbf{W}_0^{(l)}$ 为输出投影矩阵。

经过 L 层编码器后, 类标记向量 $\mathbf{Z}_{cls}^{(L)}$ 通常被归一化作为图像的全局表征向量:

$$\mathbf{h} = \text{LN}(\mathbf{Z}_{cls}^{(L)}) \quad (5-10)$$

该全局表征向量 $\mathbf{h}$ 可作为下游任务 (如分类、检测或跨模态融合) 的输入特征。

5.1.2 多模态掩蔽 Transformer 预训练方法

受到计算机视觉领域自监督技术的启发, 本节探索了用于多模态遥感图像空谱-空间特征提取的多模态掩蔽 Transformer (MSS-MTr, Multimodal Spectral-Spatial Masked Transformer)。MSS-MTr 通过在输入的多模态遥感图像中随机屏蔽部分空间块, 并利用剩余信息进行重建来预训练 Transformer 模型, 从而迫使模型不仅学习到局部空间依赖关系, 还能捕获不同模态间的互补特征与语义关联。

MSS-MTr 的整体训练流程如图 5-2 所示。一般来说, 当其应用于多模态遥感图像分类任务时, 其训练过程分为两个阶段: 预训练阶段和微调阶段。




图 5-2 基于遮蔽的多模态遥感图像分类方法总体框图

在预训练阶段, 首先将多模态图像 $\mathbf{X}_1 \in \mathbb{R}^{H \times W \times C}$, $\mathbf{X}_2 \in \mathbb{R}^{H \times W \times B}$ 分别在空间上随机掩蔽掉一些区域。具体来说, 将多模态图像样本 $\mathbf{X}_1$ 和 $\mathbf{X}_2$ 都分为 $N = HW/P^2$ 个不重叠空间块 $\bar{\mathbf{p}}$, 其中 $\bar{\mathbf{p}} \in \mathbb{R}^{N \times P^2 B/P^2 C}$, P 为空间块大小。然后针对各个模态的图像块进行随机掩

蔽，从所有图像块中随机选择一部分。图像块的索引集合定义为：

$$I = \{a | 1 \leq a \leq N, a \in \mathbb{Z}\} \quad (5-11)$$

其中 $\mathbb{Z}$ 表示整数集。然后从中按照掩蔽比例 p 随机选择 Np 个块进行掩蔽，生成需要掩蔽掉的图像块的索引：

$$I_m = \text{RandomSelect}(I, Np) \quad (5-12)$$

其中 $\text{RandomSelect}(I, Np)$ 表示从给定集合 I 中无放回地随机选择 Np 个元素，掩蔽后的各模态图像块序列为：

$$\bar{p}_i = \bar{p}[I - I_m] \in \mathbb{R}^{N(1-p) \times P^2 C / P^2 B} \quad (5-13)$$

接下来，掩蔽后的图像块序列通过可学习矩阵 $E \in \mathbb{R}^{P^2 C / P^2 B \times D}$ 进行线性变换，得到标记向量序列：

$$T_i = [t_{cls}; \bar{p}_i E] \quad (5-14)$$

其中 t_{cls} 为类标记向量，用于图像全局表征， D 表示编码器的标记维度， $T_i \in \mathbb{R}^{(N-Np+1) \times D}$ 表示掩蔽后的标记向量序列。

掩蔽后的各模态标记向量序列被输入各自的基于 Transformer 的编码器（由 L_e 层编码块组成）进行空谱-空间特征提取：

$$T_e = TE(T_i) \quad (5-15)$$

其中 $T_e \in \mathbb{R}^{(N-Np+1) \times D}$ 表示经过编码器特征提取后的标记向量， $TE(\cdot)$ 表示编码器的映射函数。

随后，编码器输出 T_e 与掩蔽标记向量 T_m 一起输入解码器（由 L_d 层 Transformer 编码块及线性层组成）进行原始多模态图像重建。其中掩蔽标记向量 T_m 用于补全输入样本并插入至被掩蔽掉的图像块位置。每个 T_m 都是一个可学习的向量，根据原始位置与编码标记向量 T_e 进行拼接，如图 5-3 所示。




图 5-3 图像掩蔽及解码排列示意图

解码器首先通过线性层将标记向量的维度从 D 转换为 D' 。然后将转换后的向量添加位置编码向量为重建任务提供位置信息，输入给 Transformer 编码块处理。最后再将输出通过另一个线性层将向量投影到像素空间。解码过程为：

$$\mathbf{T}_d = TD(\mathbf{T}_e, \mathbf{T}_m) \quad (5-16)$$

其中 $\mathbf{T}_d \in \mathbb{R}^{(N+1) \times P^2 C / P^2 B}$ 表示获得的用于重建的标记向量， $TD(\cdot)$ 表示解码器的映射函数。在不考虑类标记向量后，获得的 $\mathbf{T}_d$ 可以被重新排列成为与原始输入的多模态样本 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 形状相同的图像。

最后，仅在被掩蔽掉区域计算重建样本和原始输入样本 $\mathbf{x}_1$ 与 $\mathbf{x}_2$ 之间的均方误差。具体来说，原始多模态样本被划分为 N 个不重叠的补丁 $\mathbf{p}$ ，重建损失 $\mathcal{L}_{rec}$ 计算如下：

$$\tilde{\mathbf{p}} = \mathbf{T}_d[1:end] \quad (5-17)$$

$$\mathcal{L}_{rec} = \|\mathbf{p}[l_m] - \tilde{\mathbf{p}}[l_m]\|_2^2 \quad (5-18)$$

在微调阶段，将预训练的 Transformer 编码器后添加一个联合 Transformer 编码器，联合编码器用于将所提取到的单模态特征进行融合，学习到具有模态互补性的联合特征。最后添加一个新的全连接层，并使用交叉熵损失在有标签多模态遥感数据上进行微调，形成一个用于分类的新网络。它们的输入是未掩蔽的多模态数据，单模态编码器加载了在预训练过程中学到的参数，并用于多模态数据的特征提取。联合编码器通过自注意力机制在跨模态特征之间建立依赖关系，从而获得更鲁棒的联合特征。

5.1.3 基于类别区分性和样本差异性的掩蔽 Transformer 预训练方法

在前文中，提出了基于掩蔽重建的 MSS-MTr 方法，该方法通过随机掩蔽输入的多模态图像块并进行重建，使得模型能够在预训练阶段充分捕获各个模态数据的局部空间特征。然而，该方法主要着眼于局部上下文的恢复，所学特征在判别性方面仍然不足，一方面，不同类别之间的差异性并未得到显式建模；另一方面，同类样本与不同样本之间的实例关系也未得到有效约束。因此，单纯依赖重建的预训练方式虽然可以提升 Transformer 对局部特征的敏感性，但难以保证下游任务中分类的判别性，之后的实验可以证实这一点。

为了解决上述问题，在 MSS-MTr 的基础上，本节引入监督分类与对比学习两种机制，提出了一种具有判别性特征建模能力的预训练方法。该方法在保持重建任务的同时，进一步通过标签监督增强模型在类别区分性上的能力，使其能够更清晰地区分不同地物类别；通过对比学习增强样本差异性的建模，形成了一个统一的判别性预训练框架，如图 5-4 所示。样本差异性是指模型能够有效地区分单个样本与其他样本的能力，即使它们所属同一类别。类别区分性是强调不同类别之间的显著差异，使得模型能够在特征空间中拉开类别间的间隔。

5.1.3.1 基于对比学习的掩蔽 Transformer 预训练方法

对比学习是一种近年来在计算机视觉领域应用广泛的预训练策略，其核心思想是通过拉近同一样本的不同视图在特征空间中的距离，同时拉开不同样本之间的差异，从而

提升模型的表征能力。众所周知，这种方法能够显著增强模型在样本实例级别上的判别性。本节将对比学习思想与 MSS-MTr 框架相结合，在原有的重建分支基础上，增加了一个并行的对比学习分支，其结构如图 5-4 所示。




图 5-4 基于类别区分性和样本差异性的掩蔽 Transformer 结构示意图

在对比学习过程中，通常需要依赖数据增强来构造一个样本的两个不同视图。考虑到 MSS-MTr 的掩蔽特性，本课题利用同一样本在不同模态间的表征互补性来构造视图。具体来说，选择了掩蔽后的多模态样本和原始未掩蔽样本作为同一样本的两个视图。对于掩蔽视图 $\bar{p}_i$ ，由编码标记和掩码标记 (T_e, T_m) 组成的标记序列记为 T_1 ；而在未掩蔽视图 $\bar{p}$ 中，未掩蔽样本在编码器处理后的标记序列记为 T_2 ，其计算方式如下：

$$T_2 = [t'_{cls}; \bar{p}E] \quad (5-14)$$

在对比学习分支中， T_1 和 T_2 会分别输入到一个仅包含单层 Transformer 编码块的映射网络中，得到的输出分别为 Z_1 和 Z_2 。它们对应的类标记向量分别为 z_{cls} 和 z'_{cls} ，用于计算对比损失函数来更新模型参数。

这里采用 InfoNCE 损失来实现对比学习目标。设单个批次内有 M 个样本，则这 M 个样本的两个视图对应的类标记向量可记为：

$$\{\mathbf{h}_i\}_{i=1}^{2M}, \begin{cases} \mathbf{h}_{2k} = \mathbf{z}_{cls}^{[k]} \\ \mathbf{h}_{2k-1} = \mathbf{z}_{cls}^{[k]'} \end{cases} \quad k = 1, 2, \dots, M \quad (5-15)$$

其中 $\mathbf{z}_{cls}^{[k]}$ 和 $\mathbf{z}_{cls}^{[k]}'$ 是第 k 个样本的两个视图的类标记向量。令

$$s(\mathbf{a}, \mathbf{b}) = \mathbf{a}^T \mathbf{b} / (\|\mathbf{a}\| \|\mathbf{b}\|) \quad (5-16)$$

表示 ℓ_2 归一化后的两个向量 $\mathbf{a}$ 和 $\mathbf{b}$ 之间的内积。那么对比损失函数定义为：

$$\mathcal{L}_{cl} = \frac{1}{2M} \sum_{k=1}^M (\ell(2k-1, 2k) + \ell(2k, 2k-1)) \quad (5-17)$$

$$\ell(i, j) = -\log \frac{e^{s(\mathbf{h}_i, \mathbf{h}_j)}}{\sum_{k=1}^{2M} \mathbb{1}_{[k \neq i]} e^{s(\mathbf{h}_i, \mathbf{h}_k)}} \quad (5-18)$$

其中 $\mathbb{1}_{[\cdot]} \in \{0,1\}$ 是指示函数，当且仅当满足 $[\cdot]$ 中的条件时返回 1。与此同时，掩蔽视图的标记序列 $\mathbf{T}_1$ 还会进一步输入解码器进行重建任务，并计算对应的重建损失 $\mathcal{L}_{rec}$ 。

5.1.3.2 基于监督学习的掩蔽 Transformer 预训练方法

当多模态数据中能够获得类别标签等监督信息时，可以利用这些标签对 MSS-SS-Tr 进行额外的指导训练。与无监督或对比学习方式相比，监督信号能够更直接的刻画类内与类间的判别性，从而提升模型对不同类别特征的区分能力，为后续的下游任务奠定更加稳固的基础。

如图 5-4 所示，本小节在原有重建分支之外，增加了一个用于分类预测的监督分支。具体地，模型首先对不同模态数据进行联合编码，不同模态数据在 Transformer 编码器中相互补充。通过这种跨模态的交互建模，编码器输出的类标记向量能够同时承载多模态的全局语义信息。随后，该类标记向量被送入分类器中进行类别判别，该分类器由全连接层、ReLU 激活函数以及批量归一化层构成，如图 5-5 所示。最终输出一个预测向量 $\hat{\mathbf{y}} \in \mathbb{R}^K$ ，其中 K 是类别数目。随后，利用交叉熵损失函数衡量预测标签与真实标签之间的差异：

$$\mathcal{L}_{cls} = -\sum_{k=1}^K y_k \log \hat{y}_k \quad (5-19)$$

其中， $\hat{y}_k$ 是 $\hat{\mathbf{y}}$ 的第 k 个元素， y_k 是 one-hot 标签向量的第 k 个元素。通过监督分支的引入，模型在学习过程中不仅能够恢复局部缺失的信息，还能够多模态特征空间中建立更清晰的类间边界与类内一致性，从而获得更具判别性的表征。




图 5-5 监督学习分类器结构示意图

5.1.3.3 基于监督和对比学习的掩蔽 Transformer 预训练方法

在本节中，我们将对比学习与监督标签共同引入到 MSS-MTr 的设计与训练中，提出了一种面向多模态遥感图像分类的判别性特征学习框架 SC-MSS-MTr。与传统方法相比，该框架不仅能够对多模态样本的局部语义特征进行建模，还能够通过跨模态特征的协同刻画不同样本之间乃至跨类别之间的差异性与潜在关联性。此外，对比学习在该框架中起到正则化的作用，可以有效缓解监督训练过程中可能出现的过拟合问题。

如图 5-4 所示，SC-MSS-MTr 整体结构主要包含三个部分：

(1) 重建分支：利用掩蔽后的多模态样本视图，通过 Transformer 解码器重建缺失区域。不同模态在重建过程中独立重建，从而使模型在空间和光谱两个维度上形成更完整的各自模态表达；

(2) 监督分类分支：基于掩蔽视图经过编码器提取的多模态联合表征，输入到分类网络中进行类别判别。此时，类标记向量不仅包含单一模态的语义信息，还融合了来自多个模态的互补特征，使模型能够在类别层面形成更清晰的判别边界；

(3) 对比学习分支：将掩蔽视图与原始视图分别送入映射网络，在多模态空间中进行对比约束。通过拉近同一样本不同模态视图的特征表示，同时推远不同样本的特征表示，增强了模型在实例级别和模态级别上的判别性。

该方法的整体损失函数可定义为：

$$\mathcal{L} = \mathcal{L}_{rec} + \lambda \mathcal{L}_{cls} + \gamma \mathcal{L}_{cl} \quad (5-20)$$

其中 $\mathcal{L}_{cls}$ 表示分类损失， $\mathcal{L}_{cl}$ 表示对比学习损失。 λ 和 γ 分别为平衡各项损失的权重系数。需要强调的是，SC-MSS-MTr 则能够同时利用监督信息与无监督信息，并通过多模态特征间的互补与交互来提升表征的判别性与鲁棒性，从而显著增强模型在下游分类任务中的泛化能力。

5.2 实验部分

5.2.1 实验数据与实验设置

(1) 实验数据

休斯顿 (Houston) 数据集：该数据集由休斯顿大学与美国国家科学基金会资助的机载激光测绘中心 (NSF-funded Center for Airborne Laser Mapping) 联合开发，融合了配准后的高光谱影像与 LiDAR 高程数据。高光谱影像由 ITRES CASI-1500 传感器获取，涵盖 380–1050nm 波段，共 144 个光谱通道，空间分辨率为 2.5m；LiDAR 数据点云密度为 2.1 点/m²，垂直方向均方根误差 (RMSE) 精度为 0.5m。该数据集空间尺寸为 349×1905 像素，包含 15,029 个地面真实样本，覆盖 15 个不同类别。图 5-6 显示了休斯顿数据集的假彩色图和真实地物图。表 5-1 列出了类别的具体情况。

柏林 (Berlin) 数据集：该数据集包含配准后的高光谱影像和合成孔径雷达 (SAR) 数据，覆盖德国柏林地区。高光谱数据包含 244 个光谱波段，波段范围为 400–2500 nm，空间尺寸为 797×220 像素，可捕获城市地物的精细几何空间信息和细粒度光谱特征。互补的 SAR 数据包含 4 个通道，其像素尺寸与高光谱数据一致。该数据集包含 464,671 个已标注像素，分布于 8 个地物类别中。图 5-7 显示了柏林数据集的假彩色图和真实地物图。表 5-2 列出了类别的具体情况。

密西西比大学 (MUUFL) 数据集：该数据于 2010 年 11 月在美国密西西比州长滩的南密西西比大学 Gulfpark 校区获取，包含同步采集并完成空间配准的高光谱影像与

LiDAR 数据。高光谱数据最初包含 72 个光谱波段 (375–1050nm)，空间尺寸为 325×220 像素，但按照标准处理流程，会去除前 4 个和后 4 个受噪声影响的波段，最终保留 64 个有效的光谱通道。该数据集提供了 53,687 个地面真实样本，分布在 11 个地物类别中，涵盖城市与植被等地表类型。图 5-8 显示了柏林数据集的假彩色图和真实地物图。表 5-3 列出了类别的具体情况。




图 5-6 休斯顿数据集：(a)假彩色图，(b)LiDAR 灰度图，(c)真实地物分布

表 5-1 休斯顿数据集地物类别情况

标号	颜色	类别名称	样本数目
1		健康草	1251
2		被压草	1254
3		人工草	697
4		树	1244
5		土壤	1242
6		水	325
7		居民区	1268
8		商业区	1244
9		公路	1252
10		高速路	1227
11		铁路	1235
12		停车场-1	1233
13		停车场-2	469
14		网球场	428
15		跑道	660
总计			15029




图 5-7 柏林数据集：(a)假彩色图，(b)SAR 灰度图(b)真实地物分布

表 5-2 柏林数据集地物类别情况

标号	颜色	类别名称	样本数目
1		森林	51954
2		居民区	268642
3		工业区	19566
4		低矮植物	59282
5		土壤	17426
6		家庭菜园	13305
7		商业区	24824
8		水	6672
总计			464671




图 5-8 密西西比大学数据集：(a)假彩色图，(b)LiDAR 灰度图，(c)真实地物分布

表 5-3 密西西比大学数据集地物类别情况

标号	颜色	类别名称	样本数目
1		树木	23246
2		草地	4270
3		混合地表	6882
4		裸土和沙地	1826
5		公路	6687
6		水	466
7		建筑阴影	2233
8		建筑	6240
9		人行道	1385
10		黄色路缘	183
11		布制覆盖板	269
总计			53687

(2) 实验环境与评价指标

训练环境：Intel Core i7-12700KF, 3.00GHz, 32GBRAM, NVIDIA GeForce GTX 4060 Ti, pytorch 2.4.1, CUDA 12.4。

在评价多模态遥感图像分类算法的分类性能时，常用的三个指标是总体精度（OA）、平均精度（AA）和卡帕系数（Kappa）。它们的计算公式如下：

总体精度（Overall Accuracy, OA）：

$$OA = \frac{\sum_{i=1}^C TP_i}{N} \quad (5-21)$$

其中， TP_i 表示类别 i 的真正例数， C 是类别总数， N 是所有样本的总数。

平均精度（Average Accuracy, AA）：

$$AA = \frac{1}{C} \sum_{i=1}^C \frac{TP_i}{TP_i + FN_i} \quad (5-22)$$

其中， TP_i 表示类别 i 的真正例数， FN_i 表示类别 i 的假负例数。

Kappa 系数（Kappa）：

$$Kappa = \frac{OA - PA}{1 - PA} \quad (5-23)$$

其中， PA 是按类别分布计算的预期总体准确率，计算公式为：

$$PA = \frac{1}{N^2} \sum_{i=1}^C \left(\frac{\sum_{j=1}^C TP_{ij}}{N} \right) \left(\frac{\sum_{j=1}^C TP_{ji}}{N} \right) \quad (5-24)$$

其中， TP_{ij} 是混淆矩阵中类别 i 和 j 的交集。

(3) 实验设置

在预训练阶段，选取数据集中的随机 300 个样本作为训练样本。为了更好地利用空间信息，空间样本的大小为 27×27 ，由中心像素和相应的图像区域组成。图像分块大小为 3。实验中均采用随机梯度下降的方法进行参数更新，批量大小设置为 512，迭代次数设为 300 次。初始学习率在休斯顿、柏林、密西西比大学数据集上分别设置为 0.001、0.0005、0.001。实验中采用了余弦退火策略来动态调整学习率。本课题使用的 Transformer 编码器包含了四个编码块（ $L=4$ ），每个块包含一个 8 头自注意力层、两个归一化层和一

个多层感知机层,编码块的标记维度为 128。Transformer 解码器包含了三个编码块($L=3$),其设置与编码器相同。

在微调阶段,使用预训练阶段的 Transformer 编码器进行微调。此外,迭代次数设置为 180 次,初始学习率与预训练阶段相同,在迭代 80 次、140 次之后学习率除以 10。

5.2.2 相关实验结果

(1) 对比实验

为了验证所提方法的效果,使用了多种现有的多模态遥感图像分类方法进行比较:

MFT (多模态融合 Transformer) [86]采用了卷积层提取双模态的信息,通过在 Transformer 编码器中构造交叉注意力机制,对不同模态的互补信息进行融合。这种方法能够很好的利用 Transformer 的特性来增强融合,提升分类精度。

CCRNet (多模态卷积神经网络) [87]是一种通过双路卷积神经网络进行特征提取的多模态遥感分类模型,并在模态融合中引入了交叉重建机制,以加强融合,提升网络的分类性能。

ExViT (扩展视觉 Transformer) [88]是一种采用双分支 CNN-Transformer 混合架构的分类模型。每个分支包含了可分类卷积模块和位置共享的编码层,用于特征提取。在特征融合阶段,通过跨模态注意力模块融合不同模态的信息。这种方法通过跨模态交互学习,学习到更具代表性的联合特征,从而提升分类精度。

NCGLF² (全局-局部特征融合网络) [89]结合了卷积神经网络和 Transformer 模型,旨在通过两者的混合来增强多模态遥感图像分类的能力。卷积神经网络用来提取高频特征,Transformer 用于捕获低频特征。这种方法利用了 Transformer 的全局特征捕捉能力与卷积网络的局部特征提取能力,提升了分类性能。

FrIT (多模态分数傅里叶 Transformer) [90]提出了一种用于提取全局语义特征和序列特征的分数傅立叶 Transformer,加速 Transformer 进行有效且高效的进行学习,能够更有效地提取和融合空间-光谱信息,从而提高分类精度。

S²CrossMamba (多模态空谱-光谱交叉 Mamba) [91]是一种采用了状态空间模型的双分支网络。利用了 Mamba 的低计算复杂度来提升效率,设计了交叉状态空间模型进一步提升空间和光谱特征提取能力,同时提高了模型的效率和分类精度。

(2) 分类结果

表 5-4、表 5-5 和表 5-6 分别给出了不同分类方法在三个公共数据集上的分类结果。所有实验均重复 5 次,以更好地评估模型性能。从表中可以看出,在所有样本中随机取 300 个训练样本的情况下,本课题所提出的 SC-MSS-MTr 方法在三个数据集上均取得了最优的分类性能,无论是总体精度(OA)、平均精度(AA)还是 Kappa 系数,都显著优于现有对比方法,体现出较强的鲁棒性与泛化能力。

表 5-4 不同方法在休斯顿数据集上的分类结果（平均值±标准差）

方法 类别	MFT	CCRNet	ExViT	NCGLF ²	FrIT	S ² CrossMamba	SC-MSS-MTr
健康草	91.70±4.63	86.27±0.54	85.80±3.90	89.24±6.93	89.69±5.79	82.98 ± 4.36	94.78 ± 3.01
被压草	89.18±4.70	94.88±0.68	94.55±1.98	96.34±2.62	96.62±2.21	77.97 ± 8.97	90.71 ± 6.41
人工草	98.99±0.61	93.66±2.44	96.18±2.59	98.66±1.06	99.70±0.32	97.43 ± 1.95	94.05 ± 4.88
树	95.52±1.95	91.79±0.84	88.63±2.62	93.27±3.82	92.47±3.39	91.20 ± 2.77	95.60 ± 2.53
土壤	97.35±2.11	95.04±0.48	99.44±0.45	100.00±0.00	93.26±8.60	97.02 ± 1.14	99.68 ± 0.64
水	60.68±6.45	0.99±0.50	81.66±7.59	88.32±5.82	60.40±9.08	68.19 ± 13.14	75.79 ± 9.82
居民区	88.79±2.13	83.72±1.10	90.18±5.56	79.50±5.73	88.87±2.41	78.58 ± 13.60	90.36 ± 6.62
商业区	91.94±2.70	81.97 ± 0.03	89.89±6.80	79.72±5.40	87.68±2.23	84.13 ± 7.75	86.74 ± 8.68
公路	72.39±1.55	61.27± 2.63	83.59±5.61	66.09±10.13	83.55±5.11	76.48 ± 10.01	87.98 ± 6.89
高速路	87.93±3.53	90.76± 4.35	77.01±15.62	87.82±11.45	66.35±8.81	78.60 ± 4.46	92.22± 9.34
铁路	85.76±1.59	82.62± 0.58	89.82±3.02	87.3±6.70	89.95±1.75	94.83 ± 2.93	91.23 ± 4.75
停车场-1	86.77±4.08	73.82± 0.79	88.06±11.46	78.04±10.81	77.42±5.74	78.27 ± 3.58	88.42 ± 4.31
停车场-2	65.60±10.72	35.79 ±5.05	68.41±9.02	77.61±7.08	73.31±9.78	68.23 ± 4.40	82.28 ± 11.59
网球场	96.44±2.52	74.93±10.81	99.71±0.47	100.00±0.00	99.19±0.11	91.88 ± 4.20	100.00 ± 0.00
跑道	99.59±0.58	95.35±3.43	95.97±5.82	99.72±0.55	98.89±1.46	98.46 ± 1.23	98.71 ± 1.73
OA (%)	88.62±0.54	81.54± 0.53	88.88 ± 0.71	87.16±1.27	87.14 ± 0.82	84.61 ± 1.82	91.76 ± 1.29
AA (%)	87.24±1.07	76.19±0.76	88.59 ± 0.59	88.11±1.28	86.49 ± 0.11	84.28 ± 1.93	91.24 ± 1.10
K×100	87.69±0.59	80.00±0.58	87.98 ± 0.77	86.11±1.38	86.08 ± 0.88	83.36 ± 1.97	91.10 ± 1.40

表 5-5 不同方法在柏林数据集上的分类结果（平均值±标准差）

方法 类别	MFT	CCRNet	ExViT	NCGLF ²	FrIT	S ² CrossMamba	SC-MSS-MTr
森林	73.42±1.63	78.40±2.40	79.63±11.70	84.97±5.51	79.16±3.39	75.91 ± 5.30	83.37 ± 3.64
居民区	94.49±0.21	91.93±0.44	93.61±2.66	92.97±2.79	92.46±1.22	88.24 ± 8.12	94.72 ± 0.86
工业区	56.56±3.58	14.56±0.88	31.78±16.85	34.21±23.38	38.46±8.43	41.05 ± 15.94	40.79 ± 14.04
低矮植物	82.22±3.31	75.73±1.25	75.32±15.07	82.55±3.48	81.42±3.41	83.51 ± 9.19	87.01± 2.47
土壤	80.83±4.89	80.66±7.16	69.79±16.70	79.31±4.88	85.35±6.04	80.32 ± 8.42	71.71 ± 5.95
家庭菜园	29.22±16.45	7.86±2.86	5.49±10.46	21.03±12.76	29.01±10.29	24.77 ± 26.16	38.71 ± 6.88
商业区	14.03±1.62	19.05±2.07	36.41±7.96	30.91±16.94	27.22±4.19	29.61 ± 18.58	38.59 ± 11.07
水	63.67±8.08	37.76±10.24	37.43±25.18	23.99±19.65	64.68±16.96	22.87 ± 23.91	12.58 ± 22.76
OA (%)	81.78±0.16	77.61± 0.97	79.82 ± 3.05	81.42±1.36	81.30 ± 0.74	78.10 ± 3.71	83.48 ± 0.50
AA (%)	61.81±2.98	50.74± 2.88	53.68 ± 8.14	56.24±2.47	62.22 ± 3.00	55.79 ± 4.67	58.44 ± 2.85
K×100	69.39±0.35	62.03± 1.81	65.56 ± 7.32	69.54±1.83	69.18 ± 1.18	65.06 ± 3.93	72.81 ± 0.77

1) 休斯顿数据集：在休斯顿数据集上，SC-MSS-MTr 的 OA 达到 91.76%，AA 为 91.24%，Kappa 为 91.10%，均为最高值。相比于表现次优的 ExViT（OA=88.88%，AA=88.59%，Kappa=87.89%），SC-MSS-MTr 分别提升了 2.88%、2.65%和 3.21%，相较于基于 CNN 的方法 CCRNet，更是有超过 10%的优势。在类别精度上，SC-MSS-MTr 在树、公路、网球场、停车场等类别上表现突出。例如在“商业区”和“居民区”类别中，SC-MSS-MTr 的精度比 CCRNet 和 NCGLF 高出 5 - 10 个百分点。

2) 柏林数据集：在柏林数据集上，SC-MSS-MTr 同样取得最佳结果，OA、AA 和 Kappa 分别为 83.48%、58.44%和 72.81%。从细分类别的表现来看，柏林数据集中的商

表 5-6 不同方法在密西西比大学数据集上的分类结果（平均值±标准差）

方法 类别	MFT	CCRNet	ExViT	NCGLF ²	FrIT	S ² CrossMamba	SC-MSS-MTr
树木	95.91±1.66	95.35±0.05	95.70±1.36	93.21±2.42	96.18±1.92	94.61 ± 1.44	95.63 ± 0.52
草地	66.38±12.95	64.78±4.15	66.47±8.37	73.25±13.32	73.34±7.92	79.24 ± 7.44	72.24 ± 4.95
混合地表	76.40±9.62	75.90±0.56	71.73±12.16	70.56±9.83	74.66±2.47	69.46 ± 10.15	79.05 ± 5.96
裸土和沙地	43.01±18.54	57.33±12.97	41.70±8.56	55.23±27.51	75.43±9.13	58.14 ± 21.77	75.12 ± 12.26
公路	87.25±2.90	83.82±2.52	89.77±2.37	81.23±8.51	84.62±6.76	90.78 ± 2.76	88.16 ± 3.10
水	11.30±14.63	55.91±0.26	6.78±9.21	23.31±38.29	7.12±14.23	17.58 ± 32.76	8.83 ± 12.42
建筑阴影	61.10±10.54	31.94±20.15	59.11±11.17	65.34±8.62	72.89±9.16	65.75 ± 5.05	65.21 ± 9.61
建筑	91.47±3.93	86.88±0.40	94.31±1.44	90.91±3.51	81.53±9.54	93.23 ± 3.41	95.01 ± 1.65
人行道	30.68±19.07	7.72±0.84	34.27±8.11	12.50±8.16	25.81±7.61	19.04 ± 10.36	16.05 ± 10.07
黄色路缘	2.28±3.68	4.92± 4.31	2.15±2.82	1.44±1.80	10.91±8.74	5.81 ± 6.86	0.11 ± 0.23
布制覆盖板	11.48±19.22	8.57±29.28	14.75±20.36	33.79±32.65	26.75±25.18	46.43 ± 26.08	52.11 ± 21.23
OA (%)	83.35 ± 1.36	81.00 ± 0.33	83.28 ± 0.69	81.40±1.50	83.66 ± 2.18	84.24 ± 0.85	85.33 ± 0.55
AA (%)	52.48 ± 5.47	56.20 ± 2.19	52.43 ± 4.13	54.62±6.54	57.20 ± 3.50	58.19 ± 4.24	58.87 ± 2.87
K×100	77.57± 1.89	74.41 ± 0.48	77.49 ± 1.06	75.31±1.87	78.04 ± 2.88	78.87 ± 1.19	80.43 ± 0.73

业区与家庭菜园类别区分难度较大，对比方法在这些类别上的精度普遍偏低（不足 35%），而 SC-MSS-MTr 在这两类地物上的分类精度明显更高。

3）密西西比大学数据集：在密西西比大学数据集上，SC-MSS-MTr 再次取得最优结果，OA 达到 85.33%，AA 为 58.87%，Kappa 为 80.43%。在具体类别方面，SC-MSS-MTr 在混合地表、公路等类别上的分类表现均显著优于其他方法。

总体而言，实验结果充分证明了组合了监督分类任务、重建任务和对比学习任务的预训练方法是有效的。

（3）消融实验

表 5-7 关于预训练过程的消融实验结果(%)

是否预训练	休斯顿			密西西比大学		
	OA	AA	Kappa	OA	AA	Kappa
是	91.76	91.24	91.10	85.33	58.87	80.43
否	85.67	86.33	84.50	75.34	49.94	67.03

表 5-7 显示了经过预训练和未经预训练的消融实验结果。从这些结果可以看出，经过预训练后的模型获得了更好的分类精度。无论是在休斯顿数据集上还是在密西西比大学数据集上，三个评价标准都得到了显著提升。这表明通过预训练能够为模型提供更好的特征初始表示，使其在后续的分类任务中更容易收敛并获得更高精度，充分证明了预训练的重要性。

表 5-8 关于对比学习分支和监督学习分支的消融实验结果 OA(%)

是否对比学习	是否监督学习	休斯顿	密西西比大学
是	否	89.93	84.63
否	是	91.57	85.13
否	否	84.27	81.44
是	是	91.76	85.33

从表 5-8 可以看出, 无论是引入对比学习分支还是监督学习分支, 都能够有效提升模型的分类精度。相比于未使用任何分支的情况, 单独引入其中任意一种分支均能带来性能改善, 而当两者同时结合时, 模型表现进一步提升, 取得了最优的分类结果。这表明对比学习与监督学习在特征表示和类别判别上具有互补优势, 其协同作用能够显著增强模型在多模态遥感分类任务中的性能。

(4) 参数分析

针对遮蔽比例 p 对 SC-MSS-MTr 的影响, 探究了在不同遮蔽比例下, 模型的性能变化。图 5-9 显示了 SC-MSS-MTr 使用不同遮蔽比例 p 时获得的总体精度。可以看出, 较大的遮蔽比例会取得更好的精度, 与此同时, 总体精度对遮蔽比例的变化并不敏感。为了平衡精度和计算负担, 在实验中将遮蔽比例 p 设置为 80%。




图 5-9 不同遮蔽比例下分类精度

最后, 分析了监督分类损失的权重系数 λ 和对比学习损失的权重系数 γ 。首先固定 γ , 分析不同 λ 对分类结果的影响。如图 5-10 所示, 可以看出, λ 值过大或过小都会导致分类效果不佳。结果表明 λ 设置为 0.02 效果最佳。




图 5-10 不同的 λ 值对 MS-SS-MTr 的影响

找到最佳的 λ 后, 固定权重系数, 再分析不同 γ 对模型性能的影响。图 5-11 显示了随

着不同 γ 值对应的总体精度。与之前实验中对 λ 的分析一样， γ 值的设置也不能过大或过小。最佳值为 0.002。




图 5-11 不同的 γ 值对 MSC-SS-MTr 的影响

6. 进度安排

本课题已完成基于掩蔽 Transformer 的多模态遥感图像预训练，根据研究内容，后续工作还需完成基于视觉语言模型的未知类分类以及未知类持续学习。以下为进度安排：

2025.9.1~ 2025.10.31	查找并梳理相关资料，阅读文献，研究经典多模态遥感图像分类方法和基于深度学习的方法，实现基于掩蔽 Transformer 的多模态遥感分类框架。
2025.11.1~ 2026.2.28	研究已有的视觉语言模型在多模态遥感数据上的应用。
2026.3.1~ 2026.5.31	设计未知类分类框架，在多个数据集上进行实验验证。
2026.6.1~ 2026.8.31	研究基于持续学习的多模态遥感未知类分类方法，设计类持续学习框架。
2026.9.1~ 2026.11.30	选择合适的持续学习方法，设计持续学习模型，并进行实验验证。
2026.12.1~ 2027.2.28	针对模型所存在的问题，探索模型改进方法。
2027.3.1~ 2027.6.15	整理实验结果，撰写论文，准备答辩事项。

7. 为完成课题所需的条件和经费

7.1 已具备的条件

- (1): 实验所需的多模态遥感图像数据集已经获得。
- (2): 对遥感图像分类、深度学习等知识已经有了一定的基础。
- (3): 对实验中所需要用到的平台和编程语言已经熟悉。

7.2 所需的条件和经费

实验室已具备完善的软硬件条件。

8. 研究过程中可能遇到的问题以及解决的措施

无

9. 参考文献

- [1] 李树涛, 李聪妤, 康旭东. 多源遥感图像融合发展现状与未来展望[J]. 遥感学报, 2021, 25(01): 148-166.
- [2] 赵伍迪, 李山山, 李安, 等. 结合深度学习的高光谱与多源遥感数据融合分类[J]. 遥感学报, 2021, 25(07): 1489-1502.
- [3] 张永军, 李彦胜, 党博, 等. 多模态遥感基础大模型: 研究现状与未来展望[J]. 测绘学报, 2024, 53(10): 1942-1954.
- [4] 赵一鸣, 胡克林, 涂可龙, 等. 基于 SAR 与光学遥感影像融合的多标签场景分类方法[J]. 测绘学报, 2025, 54(05): 911-923.
- [5] 叶珍, 白璘, 何明一. 高光谱图像空谱特征提取综述[J]. 中国图象图形学报, 2021, 26(08): 1737-1763.
- [6] 杜培军, 王小美, 谭琨, 等. 利用流形学习进行高光谱遥感影像的降维与特征提取[J]. 武汉大学学报(信息科学版), 2011, 36(02): 148-152.
- [7] 张良培, 李家艺. 高光谱图像稀疏信息处理综述与展望[J]. 遥感学报, 2016, 20(05): 1091-1101.
- [8] Benediktsson J A, Palmason J A, Sveinsson J R. Classification of hyperspectral data from urban areas based on extended morphological profiles[J]. IEEE Transactions on Geoscience and Remote Sensing, 2005, 43(3): 480-491.
- [9] Xia J, Dalla Mura M, Chanussot J, et al. Random subspace ensembles for hyperspectral

- image classification with extended morphological attribute profiles[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(9): 4768-4786.
- [10] Akbarizadeh G. A New Statistical-Based Kurtosis Wavelet Energy Feature for Texture Recognition of SAR Images[J]. IEEE Transactions on Geoscience and Remote sensing, 2012, 50(11): 4358-4368.
- [11] Shen L, Jia S. Three-dimensional Gabor Wavelets for pixel-based hyperspectral imagery classification[J]. IEEE Transactions on Geoscience and Remote sensing, 2011, 49(12): 5039-5046.
- [12] Dabbiru L, Samiappan S, Nobrega R A A, et al. Fusion of synthetic aperture radar and hyperspectral imagery to detect impacts of oil spill in Gulf of Mexico[C]// 2015 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). IEEE, 2015: 1901-1904.
- [13] Liao W, Pižurica A, Bellens R, et al. Generalized Graph-Based Fusion of Hyperspectral and LiDAR Data Using Morphological Features[J]. IEEE Geoscience and Remote Sensing Letters, 2015, 12(3), 552-556.
- [14] Rasti B, Ghamisi P, Plaza J, et al. Fusion of Hyperspectral and LiDAR Data Using Sparse and Low-Rank Component Analysis[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(11):6354-6365.
- [15] Hong D, Hu J, Yao J, et al. Multimodal remote sensing benchmark datasets for land cover classification with a shared and specific feature learning model[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 178: 68-80.
- [16] Pournemat A, Adibi P, Chanussot J, Semisupervised charting for spectral multimodal manifold learning and alignment[J]. Pattern Recognition, 2021, 111.
- [17] Rasti B, Ghamisi P, Gloaguen R. Hyperspectral and LiDAR fusion using extinction profiles and total variation component analysis[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(7): 3997-4007.
- [18] Pedernana M, Marpu P R, Dalla Mura M, et al. Classification of remote sensing optical and LiDAR data using extended attribute profiles [J]. IEEE Journal of Selected Topics in Signal Processing, 2012, 6(7): 856-865.
- [19] Hinton G E, Osindero S, Teh Y W. A fast learning algorithm for deep belief nets[J]. Neural computation, 2006, 18(7): 1527-1554.
- [20] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [21] Vincent P, Larochelle H, Lajoie I, et al. Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion[J]. Journal of machine

- learning research, 2010, 11(12).
- [22] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1988, 86(11):2278-2324.
 - [23] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8):1735-1780.
 - [24] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097-1105.
 - [25] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
 - [26] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
 - [27] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
 - [28] Strudel R, Garcia R, Laptev I, et al. Segmenter: Transformer for semantic segmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 7262-7272.
 - [29] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
 - [30] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
 - [31] Touvron H, Cord M, Douze M, et al. Training data-efficient image transformers & distillation through attention[C]//International conference on machine learning. PMLR, 2021: 10347-10357.
 - [32] Wang W, Xie E, Li X, et al. Pyramid vision transformer: A versatile backbone for dense prediction without convolutions[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 568-578.
 - [33] Chen T, Kornblith S, Norouzi M, et al. A simple framework for contrastive learning of visual representations[C]//International conference on machine learning. PmLR, 2020: 1597-1607.
 - [34] He K, Fan H, Wu Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 9729-9738.

- [35] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.
- [36] He K, Chen X, Xie S, et al. Masked autoencoders are scalable vision learners[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 16000-16009.
- [37] Chen Y, Li C, Ghamisi P, et al. Deep fusion of remote sensing data for accurate classification[J]. IEEE Geoscience and Remote Sensing Letters, 2017, 14(8): 1253-1257.
- [38] Xu X, Li W, Ran Q, et al. Multisource remote sensing data classification based on convolutional neural network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 56(2): 937-949.
- [39] Benedetti P, Ienco D, Gaetano R, et al. M³Fusion: A Deep Learning Architecture for Multiscale Multimodal Multitemporal Satellite Data Fusion[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(12): 4939-4949.
- [40] Song Q, Mo F, Ding K, et al. MCFNet: Multiscale Cross-domain Fusion Network for HSI and LiDAR Data Joint Classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63: 1-12.
- [41] Feng Y, Song L, Wang L, et al. DSHFNet: Dynamic scale hierarchical fusion network based on multiattention for hyperspectral image and LiDAR data classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-14.
- [42] Hong D, Gao L, Hang R, et al. Deep encoder–decoder networks for classification of hyperspectral and LiDAR data[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 19: 1-5.
- [43] Wu X, Hong D, Chanussot J. Convolutional neural networks for multimodal remote sensing data classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-10.
- [44] Deng B, Duan P, Lu X, et al. Hyperspectral and sar image classification via graph convolutional fusion network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-11.
- [45] Hu Q, Shen Z, Sha Z, et al. Multiloss adversarial attacks for multimodal remote sensing image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-13.
- [46] Xue Z, Tan X, Yu X, et al. Deep hierarchical vision transformer for hyperspectral and

- LiDAR data classification[J]. IEEE Transactions on Image Processing, 2022, 31: 3095-3110.
- [47] Roy S K, Deria A, Hong D, et al. Multimodal fusion transformer for remote sensing image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-20.
- [48] Zhang Y, Peng Y, Tu B, et al. Local information interaction transformer for hyperspectral and LiDAR data classification[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 16: 1130-1143.
- [49] Zhao X, Zhang M, Tao R, et al. Fractional Fourier image transformer for multimodal remote sensing data classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 35(2): 2314-2326.
- [50] Yao J, Zhang B, Li C, et al. Extended vision transformer (ExViT) for land use and land cover classification: A multimodal deep learning framework[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-15.
- [51] Ding K, Lu T, Fu W, et al. Global–local transformer network for HSI and LiDAR data joint classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-13.
- [52] Zhao G, Ye Q, Sun L, et al. Joint classification of hyperspectral and LiDAR data using a hierarchical CNN and transformer[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 61: 1-16.
- [53] Hang R, Qian X, Liu Q. Cross-modality contrastive learning for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-12.
- [54] Du Y, Li X, Shi L, et al. A prototype network for hyperspectral image open-set classification based on feature invariance and weighted Pearson distance measurement[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-17.
- [55] Xie Z, Duan P, Liu W, et al. Feature consistency-based prototype network for open-set hyperspectral image classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 35(7): 9286-9296.
- [56] Yue J, Fang L, He M. Spectral-spatial latent reconstruction for open-set hyperspectral image classification[J]. IEEE Transactions on Image Processing, 2022, 31: 5227-5241.
- [57] Bi K, Li Z, Chen Y, et al. Open-set domain adaptation for hyperspectral image classification based on weighted generative adversarial networks and dynamic thresholding[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025.
- [58] Chen M, Feng S, Zhao C, et al. Fractional Fourier-based frequency-spatial–spectral prototype network for agricultural hyperspectral image open-set classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-14.

- [59] Sun Y, Liu B, Wang R, et al. Spectral–spatial MLP-like network with reciprocal points learning for open-set hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-18.
- [60] Pal D, Bose S, Banerjee B, et al. Extreme value meta-learning for few-shot open-set recognition of hyperspectral images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-16.
- [61] Atzmon Y, Chechik G. Adaptive confidence smoothing for generalized zero-shot learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 11671-11680.
- [62] Lampert C H, Nickisch H, Harmeling S. Learning to detect unseen object classes by between-class attribute transfer[C]//2009 IEEE conference on computer vision and pattern recognition. IEEE, 2009: 951-958.
- [63] Wang X, Ye Y, Gupta A. Zero-shot recognition via semantic embeddings and knowledge graphs[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6857-6866.
- [64] Naeem M F, Khan M G Z A, Xian Y, et al. I2mvformer: Large language model generated multi-view document supervision for zero-shot image classification[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 15169-15179.
- [65] Zhang J, Yang G, Hu P, et al. Semantic consistent embedding for domain adaptive zero-shot learning[J]. IEEE Transactions on Image Processing, 2023, 32: 4024-4035.
- [66] Zhang Z, Saligrama V. Zero-shot learning via joint latent similarity embedding[C]//proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 6034-6042.
- [67] Liu Y, Zhou L, Bai X, et al. Goal-oriented gaze estimation for zero-shot learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 3794-3803.
- [68] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
- [69] Kingma D P, Welling M. Auto-encoding variational bayes[J]. arXiv preprint arXiv:1312.6114, 2013.
- [70] Xian Y, Lampert C H, Schiele B, et al. Zero-Shot Learning—A Comprehensive Evaluation of the Good, the Bad and the Ugly[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(9): 2251-2265.

- [71] Zhu Y, Xie J, Liu B, et al. Learning feature-to-feature translator by alternating back-propagation for generative zero-shot learning[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 9844-9854.
- [72] Li A, Lu Z, Wang L, et al. Zero-shot scene classification for high spatial resolution remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(7): 4157-4167.
- [73] Quan J, Wu C, Wang H, et al. Structural alignment based zero-shot classification for remote sensing scenes[C]//2018 IEEE International Conference on Electronics and Communication Engineering (ICECE). IEEE, 2018: 17-21.
- [74] Wang C, Peng G, De Baets B. A distance-constrained semantic autoencoder for zero-shot remote sensing scene classification[J]. IEEE journal of selected topics in applied earth observations and remote sensing, 2021, 14: 12545-12556.
- [75] Li Y, Zhu Z, Yu J G, et al. Learning deep cross-modal embedding networks for zero-shot remote sensing image scene classification[J]. IEEE transactions on geoscience and remote sensing, 2021, 59(12): 10590-10603.
- [76] Li Z, Zhang D, Wang Y, et al. Generative adversarial networks for zero-shot remote sensing scene classification[J]. Applied sciences, 2022, 12(8): 3760.
- [77] Li X, Wen C, Hu Y, et al. RS-CLIP: Zero shot remote sensing scene classification via contrastive vision-language supervision[J]. International Journal of Applied Earth Observation and Geoinformation, 2023, 124: 103497.
- [78] Xu W, Wang J, Wei Z, et al. Deep semantic-visual alignment for zero-shot remote sensing image scene classification[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2023, 198: 140-152.
- [79] Alayrac J B, Donahue J, Luc P, et al. Flamingo: a visual language model for few-shot learning[J]. Advances in neural information processing systems, 2022, 35: 23716-23736.
- [80] Li J, Li D, Xiong C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C]//International conference on machine learning. PMLR, 2022: 12888-12900.
- [81] Li J, Li D, Savarese S, et al. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models[C]//International conference on machine learning. PMLR, 2023: 19730-19742.
- [82] Liu H, Li C, Wu Q, et al. Visual instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 34892-34916.
- [83] Zhu D, Chen J, Shen X, et al. Minigpt-4: Enhancing vision-language understanding with

- advanced large language models[J]. arXiv preprint arXiv:2304.10592, 2023.
- [84] Dai W, Li J, Li D, et al. Instructblip: Towards general-purpose vision-language models with instruction tuning[J]. Advances in neural information processing systems, 2023, 36: 49250-49267.
- [85] Liu A, Feng B, Wang B, et al. Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model[J]. arXiv preprint arXiv:2405.04434, 2024.
- [86] Roy S K, Deria A, Hong D, et al. Multimodal fusion transformer for remote sensing image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-20.
- [87] Wu X, Hong D, Chanussot J. Convolutional neural networks for multimodal remote sensing data classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-10.
- [88] Yao J, Zhang B, Li C, et al. Extended vision transformer (ExViT) for land use and land cover classification: A multimodal deep learning framework[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-15.
- [89] Tu B, Ren Q, Li J, et al. NCGLF2: Network combining global and local features for fusion of multisource remote sensing data[J]. Information Fusion, 2024, 104: 102192.
- [90] Zhao X, Zhang M, Tao R, et al. Fractional Fourier image transformer for multimodal remote sensing data classification[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022, 35(2): 2314-2326.
- [91] Zhang G, Zhang Z, Deng J, et al. S2CrossMamba: Spatial-Spectral Cross-Mamba for Multimodal Remote Sensing Image Classification[J]. IEEE Geoscience and Remote Sensing Letters, 2024.